



دانشگاه امیرکبیر
دانشکده مهندسی پزشکی

دسته‌بندی تصاویر سلول‌های خونی با یادگیری خودنظارتی

دانشجو:

علی هاتفی

استاد درس:

دکتر بغدادی

بهمن ۱۴۰۴



چکیده:

کمبود داده‌های برچسب‌خورده در حوزه‌ی تصویربرداری پزشکی، به‌ویژه در تشخیص سلول‌های خونی مرتبط با سرطان، یکی از چالش‌های اساسی در به‌کارگیری مدل‌های یادگیری عمیق محسوب می‌شود. این پژوهش با هدف کاهش وابستگی به داده‌های برچسب‌دار و بهبود تعمیم‌پذیری مدل‌های طبقه‌بندی پزشکی، چارچوبی مبتنی بر یادگیری خودنظارتی طراحی و پیاده‌سازی کرده است که در آن معماری مدرن ConvNeXt V2 در قالب یک خودرمزگذار ماسک‌شده‌ی تمام‌کانولوشنی به‌کار گرفته شد. در فاز نخست، مدل با استفاده از ماسک‌گذاری پیکسلی ۶۰٪ و بدون بهره‌گیری از برچسب‌ها پیش‌آموزش داده شد تا بازنمایی‌های معنادار از ساختارهای مورفولوژیکی سلول‌های خونی بیاموزد، و در فاز دوم، وزن‌های آموخته‌شده در قالب یک مدل طبقه‌بندی چندکلاسه تنظیم نهایی شدند. تقسیم‌بندی مستقل داده‌ها برای جلوگیری از نشت اطلاعات، به‌کارگیری Dropout و توقف زودهنگام برای کنترل بیش‌برازش، و ارزیابی جامع با استفاده از معیارهایی نظیر دقت، صحت، یادآوری، امتیاز F1 و منحنی‌های ROC، چارچوب ارزیابی این پژوهش را تشکیل دادند. نتایج نشان داد مدل پیشنهادی به صحت نهایی ۹۴/۸٪ بر روی مجموعه‌ی آزمون دست یافته و به‌ویژه در شناسایی سلول‌های سرطانی عملکرد بسیار بالایی ارائه می‌دهد. یافته‌ها حاکی از آن است که ترکیب معماری‌های کانولوشنی مدرن با یادگیری خودنظارتی می‌تواند راهکاری مؤثر و قابل اتکا برای مسائل تشخیص پزشکی مبتنی بر تصویر، به‌ویژه در سناریوهای کم‌نمونه، فراهم سازد.

کلمات کلیدی: یادگیری خودنظارتی، ConvNeXt V2، خودرمزگذار ماسک‌شده، تحلیل تصاویر پزشکی، تشخیص سرطان خون، یادگیری عمیق، طبقه‌بندی چندکلاسه، هماتولوژی

فهرست مطالب

فصل اول: مقدمه.....	۱
۱-۱- مقدمه.....	۲
۲-۱- بیان مسئله.....	۲
۳-۱- ضرورت و اهمیت پژوهش.....	۳
۴-۱- کاربرد در تحلیل تصاویر سلول‌های خونی.....	۳
۵-۱- نوآوری‌ها و هدف پژوهش.....	۳
۶-۱- روند کلی انجام پژوهش.....	۴
فصل دوم: مبانی نظری و مروری بر ادبیات موضوع.....	۵
۱-۲- مقدمه.....	۶
۲-۲- مبانی نظری پژوهش.....	۶
۱-۲-۲- یادگیری عمیق و تحلیل تصاویر.....	۶
۲-۲-۲- شبکه‌های عصبی کانولوشنی.....	۶
۳-۲-۲- یادگیری نظارت‌شده و محدودیت داده‌های برچسب‌دار.....	۷
۴-۲-۲- یادگیری خودنظارتی.....	۷
۵-۲-۲- خودرمزگذارها و خودرمزگذارهای ماسک‌شده.....	۷
۶-۲-۲- معماری‌های مدرن کانولوشنی و ConvNeXt.....	۷
۷-۲-۲- یادگیری خودنظارتی در تصاویر پزشکی.....	۸
۳-۲- پیشینه پژوهش.....	۸
۴-۲- جمع‌بندی.....	۱۱
فصل سوم : روش انجام کار.....	۱۳
۱-۳- مقدمه.....	۱۴

۱۴	۲-۳- معرفی داده‌ها
۱۴	۱-۲-۳- توصیف داده‌ی مورد استفاده
۱۵	۲-۲-۳- معرفی و ساختار اصلاح‌شده دیتاست
۱۵	۳-۲-۳- بررسی ۵ کلاس موجود
۱۶	۴-۲-۳- ویژگی‌های فنی و مزایای این نسخه
۱۷	۵-۲-۳- اندازه‌ی دیتاست و چالش‌ها
۱۹	۶-۲-۳- پیش‌پردازش داده‌ها
۲۰	۷-۲-۳- دلیل انتخاب دیتاست برای این پروژه
۲۰	۳-۳- معرفی معماری ConvNeXt V2
۲۰	۱-۳-۳- یادگیری خودنظارتی و مدل‌سازی تصویر ماسک‌شده
۲۱	۲-۳-۳- چالش مدل‌سازی تصویر ماسک‌شده در شبکه‌های کانولوشنی
۲۲	۳-۳-۳- چارچوب خودرمزگذار ماسک‌شده‌ی تمام کانولوشنی (FCMAE)
۲۲	۴-۳-۳- استراتژی ماسک‌گذاری در FCMAE
۲۲	۵-۳-۳- طراحی رمزگذار بر اساس دیدگاه داده‌های تنک
۲۳	۶-۳-۳- طراحی رمزگشا و هدف بازسازی
۲۴	۷-۳-۳- تحلیل پدیده فروپاشی ویژگی در ConvNeXt V1
۲۵	۸-۳-۳- نرمال‌سازی پاسخ سراسری (GRN)
۲۵	۹-۳-۳- معماری ConvNeXt V2
۲۶	۴-۳- پیاده‌سازی پروژه و آماده‌سازی محیط اجرا
۲۸	۵-۳- بارگذاری مجموعه‌داده و پیکربندی محیط محاسباتی
۲۸	۱-۵-۳- دریافت خودکار مجموعه‌داده و شناسایی ساختار داده‌ها
۲۹	۲-۵-۳- ملاحظات مهندسی داده و ارتباط با مبانی نظری مقاله

۳-۵-۳- مدیریت خطا و پایداری اجرای پروژه	۳۰
۳-۵-۴- پیکربندی سخت‌افزار محاسباتی	۳۰
۳-۶-۶- ابزارهای کمکی برای پایش آموزش و مصورسازی	۳۱
۳-۶-۱- توقف زودهنگام به‌عنوان راهکار کنترل بیش‌برازش	۳۱
۳-۶-۲- بازنرمال‌سازی تصاویر برای مصورسازی نتایج	۳۳
۳-۷-۷- معماری مدل پیشنهادی مبتنی بر ConvNeXt V2 و FCMAE	۳۴
۳-۷-۱- نرمال‌سازی لایه‌ای سفارشی	۳۴
۳-۷-۲- نرمال‌سازی پاسخ سراسری (GRN)	۳۴
۳-۷-۳- بلوک ConvNeXt V2	۳۵
۳-۷-۴- معماری ConvNeXt V2 Nano (رمزگذار)	۳۶
۳-۷-۵- چارچوب خودرمزگذار ماسک‌شده‌ی تمام‌کانولوشنی (FCMAE)	۳۶
۳-۷-۶- مدل تنظیم نهایی برای دسته‌بندی	۳۷
۳-۸-۸- پیش‌پردازش و تقسیم داده	۳۸
۳-۸-۱- پیش‌پردازش تصاویر و تعریف تبدیل‌ها	۳۸
۳-۸-۲- بارگذاری مجموعه‌داده و استخراج تعداد کلاس‌ها	۳۸
۳-۸-۳- استراتژی تقسیم داده	۳۹
۳-۸-۴- تعریف DataLoaderها و تنظیمات بارگذاری داده‌ها	۳۹
۳-۸-۵- گزارش آماری تقسیم داده‌ها	۴۰
۳-۹-۹- فاز اول: پیش‌آموزش خودنظارتی	۴۱
۳-۹-۱- تنظیمات بهینه‌سازی و تابع هزینه	۴۱
۳-۹-۲- استراتژی ماسک‌گذاری و روند آموزش در فاز خودنظارتی	۴۱
۳-۹-۳- ارزیابی کیفی: بازسازی تصاویر در داده‌های دیده‌نشده	۴۲

۴۲	۳-۹-۴- بازنرمال سازی تصاویر و آماده سازی برای مصورسازی
۴۳	۳-۹-۵- نمایش نتایج بازسازی (بررسی صحت بصری)
۴۳	۳-۱۰-۱- انتقال دانش از فاز اول به فاز دوم
۴۴	۳-۱۰-۱- طراحی سر طبقه بندی و راهبردهای منظم سازی
۴۴	۳-۱۰-۲- تنظیمات بهینه سازی و تابع هزینه
۴۴	۳-۱۰-۳- حلقه ی آموزش نظارت شده
۴۵	۳-۱۰-۴- مرحله ی اعتبارسنجی و پایش تعمیم پذیری مدل
۴۵	۳-۱۰-۵- ذخیره سازی و تحلیل تاریخچه ی آموزش
۴۵	۳-۱۰-۶- توقف زودهنگام
۴۶	۳-۱۱-۱- ارزیابی مدل و معیارهای عملکرد
۴۷	۳-۱۱-۱- گزارش طبقه بندی (Precision، Recall و F1-Score)
۴۷	۳-۱۱-۲- ماتریس سردرگمی
۴۸	۳-۱۱-۳- منحنی ROC چندکلاسه و مساحت زیر منحنی (AUC)
۴۸	۳-۱۱-۴- دقت نهایی مدل بر روی مجموعه ی آزمون
۴۹	۳-۱۲- جمع بندی
۵۱	فصل چهارم: نتایج
۵۲	۴-۱- مقدمه
۵۲	۴-۲- داندلود و شناسایی ساختار مجموعه داده سلول های خونی برای تشخیص سرطان
۵۳	۴-۳- تقسیم داده ها
۵۴	۴-۴- خروجی فاز اول: یادگیری بدون نظارت
۵۴	۴-۴-۱- رفتار همگرایی در آموزش خودنظارتی (SSL)
۵۵	۴-۵- نتایج نهایی

۵۵	۴-۵-۱- تحلیل منحنی‌های آموزش و اعتبارسنجی
۵۶	۴-۵-۲- گزارش طبقه‌بندی کمی
۵۷	۴-۵-۳- تحلیل ماتریس درهم‌ریختگی
۵۹	۴-۶- جمع‌بندی
۶۱	فصل پنجم: جمع‌بندی و نتیجه‌گیری
۶۲	۵-۱- مقدمه
۶۲	۵-۲- جمع‌بندی کلی پژوهش
۶۳	۵-۳- تحلیل نتایج نهایی و دستاوردهای اصلی
۶۴	۵-۴- مقایسه مفهومی با رویکردهای متداول
۶۵	۵-۵- محدودیت‌های پژوهش
۶۵	۵-۶- پیشنهادات مطالعات آتی
۶۷	مراجع

فهرست اشکال

شکل ۱-۳ اندازه دیتاست و فراوانی هر کلاس	۱۸
شکل ۲-۳ نمونه‌ی تصاویری از هر کلاس	۱۹
شکل ۳-۳ وارد کردن کتابخانه‌های مورد نظر به محیط	۲۶
شکل ۴-۳ بارگیری داده و بارگذاری آن	۲۹
شکل ۵-۳ پیاده‌سازی ابزارهای کمکی	۳۲
شکل ۶-۳ طراحی بلوک‌های ConvNeXt. در ConvNeXt V2 [۱۳]	۳۵
شکل ۷-۳ پیاده‌سازی پیش‌پردازش و تقسیم داده	۴۰
شکل ۱-۴ دالود و شناسایی ساختار مجموعه داده سلول‌های خونی برای تشخیص سرطان	۵۳
شکل ۲-۴ تقسیم داده‌ها	۵۳
شکل ۳-۴ خروجی لاگ مدل FCMAE	۵۵
شکل ۴-۴ کیفیت بازسازی FCMAE روی داده‌های دیده‌نشده در فاز یادگیری خودنظارتی	۵۵
شکل ۵-۴ منحنی‌های آموزش و اعتبارسنجی مدل ConvNeXt V2 مبتنی بر FCMAE	۵۶
شکل ۶-۴ گزارش عملکرد مدل	۵۷
شکل ۷-۴ ماتریس درهم‌ریختگی طبقه‌بندی سلول‌های خونی	۵۸
شکل ۸-۴ منحنی‌های ROC چندکلاسه برای شناسایی سلول‌های خونی	۵۹

فصل اول: مقدمه

۱-۱- مقدمه

در دهه‌ی اخیر، پیشرفت‌های چشمگیر در حوزه‌ی یادگیری عمیق موجب تحول اساسی در تحلیل داده‌های پیچیده، به‌ویژه داده‌های تصویری، شده است. شبکه‌های عصبی عمیق با بهره‌گیری از ساختارهای چندلایه و قابلیت یادگیری نمایش‌های سلسله‌مراتبی، توانسته‌اند در بسیاری از مسائل بینایی ماشین، عملکردی فراتر از روش‌های کلاسیک ارائه دهند. در این میان، شبکه‌های عصبی کانولوشنی به‌عنوان ستون فقرات اغلب سامانه‌های پردازش تصویر شناخته می‌شوند و به دلیل توانایی ذاتی در استخراج الگوهای مکانی، نقش بسیار مهمی در تحلیل تصاویر پزشکی، زیستی و میکروسکوپی ایفا می‌کنند.

با گسترش کاربردهای هوش مصنوعی در حوزه‌های زیست‌پزشکی، نیاز به روش‌هایی کارآمد برای تحلیل تصاویر پزشکی، به‌ویژه در شرایط محدودیت داده‌های برچسب‌دار، بیش از پیش احساس می‌شود.

۱-۲- بیان مسئله

با وجود موفقیت گسترده‌ی روش‌های یادگیری نظارت‌شده مبتنی بر شبکه‌های کانولوشنی، یکی از چالش‌های اساسی این رویکردها، وابستگی شدید آن‌ها به داده‌های برچسب‌دار است. فرآیند برچسب‌گذاری داده‌ها، به‌ویژه در حوزه‌ی تصاویر پزشکی و زیستی، نیازمند صرف زمان، هزینه و دانش تخصصی بالا بوده و در بسیاری از موارد امکان تهیه‌ی حجم کافی از داده‌های برچسب‌دار وجود ندارد. در مقابل، حجم قابل‌توجهی از داده‌های بدون برچسب در دسترس است که به‌صورت مستقیم در روش‌های نظارت‌شده قابل استفاده نیستند.

در پاسخ به این چالش، روش‌های یادگیری خودنظارتی معرفی شده‌اند که هدف آن‌ها استخراج نمایش‌های معنادار از داده‌ها بدون استفاده از برچسب‌های صریح است. در این میان، خودرمزگذارهای ماسک‌شده^۱ به‌عنوان یکی از موفق‌ترین چارچوب‌های یادگیری خودنظارتی در حوزه‌ی بینایی ماشین مطرح شده‌اند. با این حال، بسیاری از پیاده‌سازی‌های موفق این روش‌ها بر پایه‌ی معماری‌های ترنسفورمری استوار هستند که به‌رغم صحت بالا، از هزینه‌ی محاسباتی زیاد و نیاز به منابع سخت‌افزاری گسترده رنج می‌برند.

از سوی دیگر، اگرچه معماری‌های کانولوشنی به دلیل بهره‌وری محاسباتی بالاتر همچنان جذاب هستند، اما نسخه‌های کلاسیک آن‌ها برای ترکیب مؤثر با یادگیری خودنظارتی، به‌ویژه در قالب خودرمزگذارهای ماسک‌شده، بهینه‌سازی نشده‌اند. این موضوع شکاف روشنی را میان کارایی محاسباتی و توان یادگیری نمایش‌های غنی ایجاد کرده است.

¹ Masked Auto Encoder

۱-۳- ضرورت و اهمیت پژوهش

در راستای پر کردن این شکاف، معماری ConvNeXt و نسخه‌ی توسعه‌یافته‌ی آن، ConvNeXt V2، به‌عنوان تلاش‌هایی برای بازطراحی شبکه‌های کانولوشنی با الهام از اصول موفق معماری‌های ترنسفورمری معرفی شده‌اند. ConvNeXt V2 با تلفیق طراحی مدرن شبکه‌های کانولوشنی و چارچوب یادگیری خودنظارتی، امکان پیاده‌سازی خودرمزگذار ماسک‌شده‌ی تمام کانولوشنی را فراهم می‌کند. این معماری با معرفی مؤلفه‌هایی نظیر نرمال‌سازی پاسخ سراسری^۱، پایداری آموزش و کیفیت نمایش‌های یادگرفته‌شده را بهبود می‌بخشد.

با توجه به اهمیت تحلیل تصاویر پزشکی، به‌ویژه تصاویر سلول‌های خونی مرتبط با تشخیص بیماری‌هایی نظیر سرطان، استفاده از رویکردهای یادگیری خودنظارتی مبتنی بر معماری‌های کانولوشنی مدرن از ضرورت بالایی برخوردار است. این پژوهش با تمرکز بر به‌کارگیری ConvNeXt V2 در یک چارچوب خودنظارتی، تلاش می‌کند تا با استفاده‌ی مؤثر از داده‌های بدون برچسب، نمایش‌های معناداری استخراج کند که در نهایت موجب بهبود عملکرد طبقه‌بندی در شرایط محدودیت داده‌های برچسب‌دار شود. بدین ترتیب، نتایج این پژوهش می‌تواند گامی مؤثر در جهت توسعه‌ی روش‌های عملی و کم‌هزینه برای تحلیل داده‌های تصویری پزشکی محسوب شود.

۱-۴- کاربرد در تحلیل تصاویر سلول‌های خونی

با توجه به اهمیت تحلیل تصاویر زیستی و پزشکی، استفاده از روش‌های یادگیری خودنظارتی در این حوزه از جذابیت ویژه‌ای برخوردار است. در این پروژه، تمرکز بر پیاده‌سازی معماری ConvNeXt V2 و به‌کارگیری آن در یک چارچوب یادگیری خودنظارتی مبتنی بر خودرمزگذار ماسک‌شده برای تحلیل تصاویر سلول‌های خونی قرار دارد. مجموعه‌داده‌ی مورد استفاده شامل تصاویر میکروسکوپی سلول‌های خونی مرتبط با تشخیص سرطان است که نمونه‌ای از داده‌های واقعی با محدودیت در برچسب‌گذاری محسوب می‌شود. هدف اصلی، استخراج نمایش‌های معنادار از داده‌های بدون برچسب و استفاده از آن‌ها برای بهبود عملکرد طبقه‌بندی است.

۱-۵- نوآوری‌ها و هدف پژوهش

از ویژگی‌های مهم این پروژه، پیاده‌سازی کامل و دستی معماری مدل بدون استفاده از پیاده‌سازی‌های آماده است که امکان درک عمیق‌تر از جزئیات معماری و تأثیر هر یک از مؤلفه‌ها بر عملکرد نهایی مدل را فراهم می‌کند. همچنین، با به‌کارگیری روش‌هایی مانند توقف زودهنگام تلاش شده است تا مدل برای کار با مجموعه‌داده‌های کوچک و تخصصی بهینه‌سازی شود. هدف نهایی این پژوهش، بررسی کارایی یادگیری خودنظارتی مبتنی بر

¹ General Response Normalization

خودرمزگذار ماسک شده در استخراج نمایش های مفید از تصاویر سلول های خونی و ارزیابی تأثیر این نمایش ها بر عملکرد طبقه بندی نهایی است. نتایج این پژوهش می تواند نشان دهد که ترکیب معماری های کانولوشنی مدرن با یادگیری خودنظارتی، راهکاری مؤثر برای تحلیل داده های تصویری پزشکی با محدودیت برچسب گذاری ارائه می دهد.

۱-۶- روند کلی انجام پژوهش

در راستای رعایت اصول صحیح یادگیری خودنظارتی، داده های مورد استفاده در مرحله ی پیش آموزش خودنظارتی و مرحله ی آموزش نظارت شده به صورت کاملاً مجزا در نظر گرفته شده اند تا از بروز نشت اطلاعات جلوگیری شود. در مرحله ی نخست، مدل به صورت خودنظارتی و بدون استفاده از برچسب ها آموزش داده می شود و وظیفه ی آن بازسازی تصویر کامل از نسخه ی ماسک شده ی ورودی است. پس از اتمام این مرحله، بخش رمزگشا^۱ حذف شده و رمزگذار^۲ به عنوان استخراج کننده ی ویژگی مورد استفاده قرار می گیرد. در مرحله ی دوم، این رمزگذار با استفاده از داده های برچسب دار و در قالب یک مدل طبقه بندی، تنظیم نهایی می شود.

^۱ Encoder

^۲ Decoder

فصل دوم: مبانی نظری و مروری بر ادبیات موضوع

۲-۱- مقدمه

در این فصل، مبانی نظری و پیشینه‌ی پژوهش‌های مرتبط با موضوع تحقیق ارائه می‌شود تا چارچوب مفهومی لازم برای درک روش پیشنهادی فراهم گردد. ابتدا مفاهیم پایه‌ای یادگیری عمیق، شبکه‌های عصبی کانولوشنی و محدودیت‌های یادگیری نظارت‌شده مورد بررسی قرار می‌گیرد و سپس رویکرد یادگیری خودنظارتی و نقش خودرمزگذارهای ماسک‌شده در یادگیری بازنمایی‌های تصویری تشریح می‌شود. در ادامه، معماری‌های کانولوشنی مدرن، به‌ویژه ConvNeXt و ConvNeXt V2، و کاربرد روش‌های یادگیری خودنظارتی در تحلیل تصاویر پزشکی مرور شده و در نهایت، با تحلیل انتقادی مطالعات پیشین، خلأ پژوهشی موجود که مبنای انجام پژوهش حاضر است، تبیین می‌شود.

۲-۲- مبانی نظری پژوهش

۲-۲-۱- یادگیری عمیق و تحلیل تصاویر

یادگیری عمیق به‌عنوان یکی از شاخه‌های پیشرفته‌ی یادگیری ماشین، با استفاده از شبکه‌های عصبی چندلایه امکان استخراج بازنمایی‌های پیچیده و سلسله‌مراتبی از داده‌ها را فراهم می‌کند. در حوزه‌ی تحلیل تصاویر، این رویکرد نقش کلیدی در پیشرفت وظایفی نظیر طبقه‌بندی، تشخیص اشیاء و بخش‌بندی ایفا کرده است. شبکه‌های عصبی عمیق قادرند بدون نیاز به طراحی دستی ویژگی‌ها، الگوهای معنادار را مستقیماً از داده‌های خام استخراج کنند، امری که به‌ویژه در داده‌های تصویری با ابعاد بالا اهمیت دارد [۱].

۲-۲-۲- شبکه‌های عصبی کانولوشنی

شبکه‌های عصبی کانولوشنی^۱ (CNNs) یکی از مهم‌ترین معماری‌ها در یادگیری عمیق برای پردازش داده‌های تصویری محسوب می‌شوند. این شبکه‌ها با استفاده از عملگر کانولوشن، قابلیت استخراج الگوهای مکانی محلی مانند لبه‌ها، بافت‌ها و ساختارهای پیچیده‌تر را دارند. ویژگی اشتراک وزن و ناحیه‌ی دریافت محلی باعث کاهش تعداد پارامترها و افزایش کارایی محاسباتی CNN‌ها شده است، به‌طوری‌که این معماری به ستون فقرات اغلب سامانه‌های بینایی ماشین تبدیل شده است [۲].

^۱ convolutional neural networks

۲-۲-۳- یادگیری نظارت‌شده و محدودیت داده‌های برچسب‌دار

در یادگیری نظارت‌شده، مدل با استفاده از داده‌های برچسب‌دار آموزش داده می‌شود و هدف آن یادگیری نگاشت میان ورودی و خروجی مشخص است. با وجود موفقیت گسترده‌ی این رویکرد، تهیه‌ی داده‌های برچسب‌دار، به‌ویژه در حوزه‌ی تصاویر پزشکی و زیستی، فرآیندی پرهزینه، زمان‌بر و وابسته به تخصص انسانی است. این محدودیت موجب شده است که در بسیاری از کاربردهای واقعی، حجم داده‌های بدون برچسب به‌مراتب بیشتر از داده‌های برچسب‌دار باشد [۳].

۲-۲-۴- یادگیری خودنظارتی

یادگیری خودنظارتی به‌عنوان زیرمجموعه‌ای از یادگیری بدون نظارت، با هدف استخراج بازنمایی‌های معنادار از داده‌ها بدون استفاده از برچسب‌های صریح معرفی شده است. در این رویکرد، برچسب‌ها از خود داده‌ها و از طریق تعریف یک وظیفه‌ی جانبی^۱ تولید می‌شوند. یادگیری خودنظارتی این امکان را فراهم می‌کند که از حجم بالای داده‌های بدون برچسب برای پیش‌آموزش مدل‌ها استفاده شده و عملکرد آن‌ها در وظایف پایین‌دستی بهبود یابد [۴].

۲-۲-۵- خودرمزگذارها و خودرمزگذارهای ماسک‌شده

خودرمزگذارها^۲ شبکه‌هایی هستند که با فشردن داده در فضای نهان و بازسازی مجدد آن، به یادگیری بازنمایی‌های مؤثر می‌پردازند. خودرمزگذارهای ماسک‌شده^۳ (MAE) با حذف تصادفی بخش بزرگی از ورودی و بازسازی نواحی حذف‌شده، مدل را وادار به درک ساختار کلی و روابط معنایی داده می‌کنند. این رویکرد در سال‌های اخیر به‌عنوان یکی از موفق‌ترین چارچوب‌های یادگیری خودنظارتی در بینایی ماشین مطرح شده است [۵].

۲-۲-۶- معماری‌های مدرن کانولوشنی و ConvNeXt

با ظهور معماری‌های ترنسفورمری، پژوهشگران به بازنگری در طراحی شبکه‌های کانولوشنی پرداختند. ConvNeXt نتیجه‌ی بازطراحی سیستماتیک شبکه‌های کانولوشنی کلاسیک با الهام از اصول موفق معماری‌های

^۱ Pretext Task

^۲ Auto Encoder

ترنسفورمری است. این معماری نشان داد که با اصلاح مؤلفه‌هایی مانند نرمال‌سازی، اندازه‌ی کرنل و ترتیب لایه‌ها، شبکه‌های کانولوشنی خالص می‌توانند عملکردی هم‌سطح یا حتی بهتر از ترنسفورمرها ارائه دهند [۶].

۲-۷- یادگیری خودنظارتی در تصاویر پزشکی

در حوزه‌ی تصویربرداری پزشکی، یادگیری خودنظارتی به دلیل کمبود داده‌های برچسب‌دار اهمیت ویژه‌ای دارد. مطالعات نشان داده‌اند که پیش‌آموزش مدل‌ها با داده‌های پزشکی بدون برچسب می‌تواند منجر به بهبود قابل‌توجه عملکرد در وظایف تشخیصی شود. این رویکرد به‌ویژه در تحلیل تصاویر میکروسکوپی و سلولی کاربرد گسترده‌ای یافته است [۷].

۲-۳- پیشینه پژوهش

جیا^۱ و همکاران (۲۰۲۴)، طی مطالعه‌ای با عنوان «یک الگوریتم طبقه‌بندی تصویر ریزدانه مبتنی بر یادگیری خودنظارتی و ترکیب چند ویژگی سلول‌های خونی» به بررسی بهبود دقت تشخیص انواع لوسمی از طریق تحلیل تصاویر سلول‌های خونی پرداختند. در این پژوهش، با استفاده از یادگیری خودنظارتی مبتنی بر خودرمزگذار ماسک‌شده و پیش‌آموزش یک مدل ترنسفورمری بر روی مجموعه‌داده‌های TMAMD و Red4، وزن‌های آموخته‌شده به مرحله‌ی طبقه‌بندی منتقل شدند. نتایج نشان داد که ترکیب ویژگی‌های استخراج‌شده از لایه‌های مختلف رمزگذار، به همراه به‌کارگیری تابع هزینه‌ی ArcFace با حاشیه‌های پویا، منجر به بهبود قابل‌توجه عملکرد طبقه‌بندی و دستیابی به صحت ۹۳/۵۱٪ و ۸۱/۴۱٪ در دو مجموعه‌داده‌ی مذکور شده است. با این حال، این مطالعه مبتنی بر معماری‌های ترنسفورمری بوده و اثرگذاری معماری‌های کانولوشنی مدرن در چارچوب یادگیری خودنظارتی برای تصاویر سلول‌های خونی به‌صورت مستقل مورد بررسی قرار نگرفته است [۸].

وو^۲ و همکاران (۲۰۲۳)، طی مطالعه‌ای با عنوان «ConvNeXt V2: طراحی مشترک و مقیاس‌بندی شبکه‌های عصبی کانولوشنی با رمزگذارهای خودکار ماسک‌دار» به بررسی بهبود عملکرد شبکه‌های عصبی کانولوشنی در چارچوب یادگیری خودنظارتی پرداختند. در این پژوهش، یک چارچوب خودرمزگذار ماسک‌شده‌ی کاملاً کانولوشنی به همراه لایه‌ی نرمال‌سازی پاسخ سراسری^۳ (GRN) طراحی و به معماری ConvNeXt افزوده شد تا یادگیری بازنمایی‌های غنی‌تر امکان‌پذیر شود. نتایج تجربی نشان داد که معماری ConvNeXt V2 در وظایف مختلف بینایی ماشین از جمله طبقه‌بندی ImageNet، تشخیص اشیاء COCO و بخش‌بندی ADE20K،

^۱ Jia

^۲ Woo

^۳ Global Response Normalization

عملکردی رقابتی و بهبودیافته نسبت به نسخه‌های پیشین ارائه می‌دهد. با این حال، ارزیابی این معماری عمدتاً بر روی مجموعه داده‌های عمومی و بزرگ مقیاس انجام شده و کارایی آن در حوزه‌های تخصصی نظیر تصاویر پزشکی و زیستی با داده‌های محدود به‌طور مستقیم بررسی نشده است [۹].

هوانگ^۱ و همکاران (۲۰۲۳)، طی مطالعه‌ای با عنوان «یادگیری خودنظارتی برای طبقه‌بندی تصاویر پزشکی: یک بررسی سیستماتیک و دستورالعمل‌های پیاده‌سازی» به بررسی جامع کاربرد روش‌های یادگیری خودنظارتی در طبقه‌بندی تصاویر پزشکی پرداختند. در این پژوهش، با انجام یک مرور سیستماتیک بر مطالعات منتشر شده بین سال‌های ۲۰۱۲ تا ۲۰۲۲ در پایگاه‌های PubMed، Scopus و ArXiv، استراتژی‌های مختلف یادگیری خودنظارتی مورد تحلیل قرار گرفت. نتایج این بررسی، پس از غربالگری ۴۱۲ مطالعه و تحلیل نهایی ۷۹ مقاله، نشان داد که یادگیری خودنظارتی می‌تواند به‌طور معناداری وابستگی مدل‌های تصویربرداری پزشکی به داده‌های برچسب‌دار را کاهش داده و عملکرد طبقه‌بندی را بهبود بخشد. با این حال، این مطالعه به ارائه‌ی چارچوب یا ارزیابی تجربی یک معماری مشخص محدود بوده و عملکرد عملی معماری‌های نوین کانولوشنی مبتنی بر خودرمزگذارهای ماسک‌شده در داده‌های تخصصی پزشکی به‌صورت تجربی بررسی نشده است [۷].

هی^۲ و همکاران (۲۰۲۲)، طی مطالعه‌ای با عنوان «خودرمزگذارهای ماسک‌شده، یادگیرنده‌های بینایی مقیاس‌پذیر هستند» به بررسی قابلیت مقیاس‌پذیری روش‌های یادگیری خودنظارتی مبتنی بر خودرمزگذارهای ماسک‌شده در حوزه‌ی بینایی ماشین پرداختند. در این پژوهش، با ماسک‌کردن تصادفی بخش بزرگی از تکه‌های تصویر ورودی و بازسازی پیکسل‌های حذف‌شده، یک معماری رمزگذار-رمزگشای نامتقارن شامل یک رمزگذار مبتنی بر تکه‌های قابل مشاهده و یک رمزگشای سبک طراحی شد. نتایج نشان داد که رویکرد MAE امکان آموزش کارآمد مدل‌های بزرگ را فراهم کرده و ضمن افزایش سرعت آموزش، دقت بالایی در وظایف مختلف بینایی ماشین از جمله طبقه‌بندی ImageNet به دست می‌آورد. با این حال، این مطالعه عمدتاً بر معماری‌های مبتنی بر ترنسفورمر و مجموعه داده‌های عمومی متمرکز بوده و بررسی مستقیمی از کارایی این روش در معماری‌های کانولوشنی یا داده‌های تخصصی نظیر تصاویر پزشکی ارائه نشده است [۵].

لیو^۳ و همکاران (۲۰۲۲)، طی مطالعه‌ای با عنوان «یک شبکه عصبی کانولوشنی برای دهه ۲۰۲۰» به بررسی امکان رقابت شبکه‌های عصبی کانولوشنی خالص با معماری‌های مبتنی بر ترنسفورمر در وظایف عمومی بینایی ماشین

¹ Huang

² He

³ Liu

پرداختند. در این پژوهش، با بازطراحی تدریجی یک معماری ResNet کلاسیک و همسو کردن مؤلفه‌های آن با اصول طراحی مدل‌های ترنسفورمری مدرن، فضای طراحی شبکه‌های کانولوشنی به‌صورت نظام‌مند مورد بررسی قرار گرفت. نتایج نشان داد که معماری پیشنهادی ConvNeXt، با وجود استفاده‌ی صرف از ماژول‌های کانولوشنی استاندارد، از نظر دقت و مقیاس‌پذیری با مدل‌های ترنسفورمری رقابت کرده و در برخی وظایف از جمله تشخیص اشیاء COCO و بخش‌بندی ADE20K عملکرد بهتری ارائه می‌دهد. با این حال، این مطالعه عمدتاً بر سناریوهای یادگیری نظارت‌شده و مجموعه‌داده‌های بزرگ مقیاس متمرکز بوده و قابلیت این معماری برای یادگیری خودنظارتی یا کاربرد در حوزه‌های تخصصی با داده‌های محدود به‌طور مستقیم بررسی نشده است [۶].

بائو^۱ و همکاران (۲۰۲۲)، طی مطالعه‌ای با عنوان «BEiT: پیش‌آموزش BERT برای تبدیل‌کننده‌های تصویر» به بررسی توسعه‌ی یک چارچوب یادگیری خودنظارتی مبتنی بر مدل‌سازی تصویر ماسک‌شده برای پیش‌آموزش تبدیل‌کننده‌های بینایی پرداختند. در این پژوهش، با الهام از مدل BERT در پردازش زبان طبیعی، تصاویر به توکن‌های بصری گسسته تبدیل شده و با ماسک کردن تصادفی بخشی از تکه‌های تصویر، مدل ترنسفورمری برای بازسازی توکن‌های اصلی آموزش داده شد. نتایج تجربی نشان داد که مدل BEiT در وظایف پایین‌دستی مانند طبقه‌بندی تصویر و تقسیم‌بندی معنایی، عملکردی رقابتی و در برخی موارد برتر نسبت به روش‌های پیش‌آموزش پیشین ارائه می‌دهد. با این حال، این روش مبتنی بر معماری‌های ترنسفورمری بوده و هزینه‌ی محاسباتی بالایی دارد، و همچنین قابلیت تعمیم آن به معماری‌های کانولوشنی یا داده‌های تخصصی پزشکی به‌صورت مستقیم مورد بررسی قرار نگرفته است [۱۰].

چن^۲ و همکاران (۲۰۲۰)، طی مطالعه‌ای با عنوان «یک چارچوب ساده برای یادگیری مقابله‌ای بازنمایی‌های بصری» به بررسی یادگیری خودنظارتی مبتنی بر رویکرد مقابله‌ای برای استخراج بازنمایی‌های بصری مؤثر پرداختند. در این پژوهش، چارچوب SimCLR بدون نیاز به معماری‌های تخصصی یا بانک حافظه طراحی شد و با استفاده از افزایش‌های داده‌ی متنوع، یک تبدیل غیرخطی قابل یادگیری و دسته‌های آموزشی بزرگ، فرایند یادگیری بازنمایی‌ها بهبود یافت. نتایج نشان داد که بازنمایی‌های آموخته‌شده توسط SimCLR در وظایف پایین‌دستی، از جمله طبقه‌بندی ImageNet، عملکردی قابل‌مقایسه با مدل‌های نظارت‌شده ارائه می‌دهند و حتی در شرایط استفاده از درصد کمی از داده‌های برچسب‌دار نیز نتایج رقابتی حاصل می‌شود. با این حال، وابستگی

¹ Bao

² Chen

این روش به اندازه‌ی دسته‌های بزرگ و نیاز به افزایش‌های داده‌ی دقیق می‌تواند استفاده‌ی عملی آن را در مجموعه‌داده‌های کوچک یا تخصصی، مانند تصاویر پزشکی، با محدودیت مواجه کند [۱۱].

۲-۴- جمع‌بندی

بر اساس مبانی نظری ارائه‌شده در این فصل، یادگیری عمیق و به‌ویژه شبکه‌های عصبی کانولوشنی نقش محوری در تحلیل داده‌های تصویری ایفا می‌کنند و به‌طور گسترده در مسائل بینایی ماشین مورد استفاده قرار گرفته‌اند. با این حال، وابستگی روش‌های یادگیری نظارت‌شده به داده‌های برچسب‌دار، به‌خصوص در حوزه‌ی تصاویر پزشکی و زیستی، یکی از چالش‌های اساسی این رویکردها محسوب می‌شود. این محدودیت، توجه پژوهشگران را به سمت یادگیری خودنظارتی معطوف کرده است؛ رویکردی که با تعریف وظایف پیش‌متنی، امکان بهره‌گیری مؤثر از داده‌های بدون برچسب را فراهم می‌کند.

در این میان، خودرمزگذارهای ماسک‌شده به‌عنوان یکی از موفق‌ترین چارچوب‌های یادگیری خودنظارتی مطرح شده‌اند و مطالعات متعددی نشان داده‌اند که این روش‌ها قادر به یادگیری بازنمایی‌های غنی و تعمیم‌پذیر از تصاویر هستند. با این وجود، بخش عمده‌ای از پژوهش‌های انجام‌شده در این حوزه، بر معماری‌های مبتنی بر ترنسفورمر متمرکز بوده‌اند؛ معماری‌هایی که اگرچه از نظر صحت عملکرد بالایی دارند، اما هزینه‌ی محاسباتی زیاد و نیاز به منابع سخت‌افزاری گسترده، استفاده‌ی عملی آن‌ها را در بسیاری از کاربردهای پزشکی محدود می‌کند.

از سوی دیگر، بازطراحی شبکه‌های کانولوشنی در قالب معماری‌های مدرن مانند ConvNeXt نشان داده است که ConvNet‌های خالص نیز می‌توانند از نظر صحت و مقیاس‌پذیری با ترنسفورمرها رقابت کنند. با این حال، نتایج پیشینه پژوهش نشان می‌دهد که نسخه‌های اولیه این معماری‌ها عمدتاً برای یادگیری نظارت‌شده توسعه یافته‌اند و به‌کارگیری مستقیم آن‌ها در چارچوب یادگیری خودنظارتی، به‌ویژه در قالب Masked Image Modeling، با چالش‌هایی نظیر نشت اطلاعات و فروپاشی ویژگی‌ها همراه بوده است. معماری ConvNeXt V2 با معرفی چارچوب خودرمزگذار ماسک‌شده‌ی تمام‌کانولوشنی و لایه‌ی نرمال‌سازی پاسخ سراسری، گامی مهم در جهت رفع این چالش‌ها برداشته است؛ با این وجود، ارزیابی‌های ارائه‌شده در مطالعات موجود عمدتاً بر روی مجموعه‌داده‌های عمومی و بزرگ مقیاس انجام شده‌اند.

در حوزه‌ی تصاویر پزشکی و به‌طور خاص تصاویر سلول‌های خونی، مرور پیشینه پژوهش نشان می‌دهد که اگرچه یادگیری خودنظارتی توانسته است عملکرد طبقه‌بندی را بهبود دهد، اما اغلب مطالعات از معماری‌های ترنسفورمری استفاده کرده‌اند و بررسی مستقلی از کارایی معماری‌های کانولوشنی مدرن در چارچوب یادگیری خودنظارتی برای

داده‌های پزشکی کوچک و تخصصی کمتر مورد توجه قرار گرفته است. همچنین، تأثیر استفاده از خودرمزگذارهای ماسک‌شده‌ی کاملاً کانولوشنی بر یادگیری نمایش‌های مورفولوژیکی ظریف سلول‌های خونی و انتقال این نمایش‌ها به وظیفه‌ی طبقه‌بندی، به‌صورت نظام‌مند بررسی نشده است.

بر این اساس، خلأ اصلی پژوهش حاضر را می‌توان در نبود ارزیابی تجربی جامع از کارایی معماری ConvNeXt V2 در قالب یادگیری خودنظارتی مبتنی بر خودرمزگذار ماسک‌شده برای تحلیل تصاویر سلول‌های خونی با داده‌های محدود و پزشکی‌محور دانست. پژوهش حاضر با تمرکز بر پیاده‌سازی کامل و مستقل معماری ConvNeXt V2 در چارچوب FCMAE و به‌کارگیری آن بر روی مجموعه‌داده‌ی واقعی تصاویر سلول‌های خونی، تلاش می‌کند این خلأ را پوشش دهد. در فصل سوم، روش انجام کار، شامل معرفی دقیق داده‌ها، معماری مدل پیشنهادی، مراحل پیش‌آموزش خودنظارتی و تنظیم نهایی نظارت‌شده، به‌صورت گام‌به‌گام تشریح خواهد شد.

فصل سوم : روش انجام کار

۳-۱- مقدمه

در این فصل، روش انجام پژوهش به صورت گام به گام و با جزئیات کامل تشریح می شود. ابتدا مجموعه داده‌ی مورد استفاده، شامل تصاویر میکروسکوپی سلول‌های خونی مرتبط با تشخیص سرطان، معرفی شده و ویژگی‌ها، چالش‌ها و دلایل انتخاب آن بررسی می گردد. سپس چارچوب کلی روش پیشنهادی ارائه می شود که مبتنی بر یادگیری خودنظارتی با استفاده از خودرمزگذار ماسک شده‌ی تمام کانولوشنی و معماری ConvNeXt V2 است. در ادامه، معماری مدل، نحوه‌ی پیاده سازی چارچوب FCMAE، استراتژی ماسک گذاری، مراحل پیش آموزش خودنظارتی و انتقال دانش به مرحله‌ی یادگیری نظارت شده به تفصیل توضیح داده می شود. همچنین، جزئیات مربوط به پیش پردازش داده‌ها، تنظیمات آموزش، معیارهای ارزیابی و ملاحظات مهندسی به کاررفته برای کار با داده‌های پزشکی با حجم محدود ارائه خواهد شد. هدف این فصل، ارائه‌ی یک توصیف شفاف و بازتولیدپذیر از فرآیند انجام پژوهش است تا زمینه‌ی تحلیل نتایج و ارزیابی عملکرد روش پیشنهادی در فصل‌های بعدی فراهم شود.

۳-۲- معرفی داده‌ها

۳-۲-۱- توصیف داده‌ی مورد استفاده

در این پژوهش، از مجموعه داده‌ی Blood Cell Images for Cancer Detection استفاده شده است که شامل تصاویر میکروسکوپی سلول‌های خونی با هدف تشخیص بدخیمی‌های خونی^۱، به ویژه لوسمی، می باشد. این مجموعه داده از پلتفرم Kaggle دریافت شده و به طور خاص برای مسائل طبقه بندی تصاویر پزشکی در حوزه‌ی هماتولوژی طراحی شده است [۱۲]. ساختار و محتوای این داده‌ها امکان ارزیابی روش‌های یادگیری عمیق را در یک سناریوی واقعی پزشکی با محدودیت برچسب گذاری فراهم می کند. در فرآیند پیاده سازی پروژه، مجموعه داده به صورت خودکار دریافت شده است تا اصل بازتولیدپذیری^۲ آزمایش‌ها حفظ شده و امکان تکرار دقیق نتایج در شرایط یکسان فراهم گردد.

¹ Leukemia

² Reproducibility

۳-۲-۲- معرفی و ساختار اصلاح شده دیتاست

این مجموعه داده شامل ۵۰۰۰ تصویر میکروسکوپی از سلول‌های خونی است که به‌طور دقیق در قالب ۵ کلاس مجزا سازمان‌دهی شده‌اند. از نکات قابل توجه این مجموعه داده، توزیع کاملاً متوازن^۱ نمونه‌ها میان کلاس‌ها است؛ به‌گونه‌ای که برای هر کلاس دقیقاً ۱۰۰۰ تصویر در نظر گرفته شده است. این توازن کلاسی یک مزیت مهم در آموزش مدل‌های یادگیری عمیق محسوب می‌شود، زیرا از بروز سوگیری^۲ مدل به سمت کلاس‌های پرتعداد جلوگیری کرده و نیاز به به‌کارگیری روش‌های پیچیده برای مقابله با عدم تعادل داده‌ها را برطرف می‌سازد.

۳-۲-۳- بررسی ۵ کلاس موجود

بر اساس نمودار توزیع کلاس‌ها، این مجموعه داده شامل ترکیبی از سلول‌های طبیعی، سلول‌های نابالغ و سلول‌های مرتبط با بیماری‌های خونی است. تنوع زیستی موجود در این داده‌ها، امکان ارزیابی دقیق مدل در تفکیک الگوهای مورفولوژیکی مختلف را فراهم می‌کند. جزئیات هر یک از کلاس‌ها به شرح زیر است:

(۱) بازوفیل^۳: یکی از انواع گلبول‌های سفید طبیعی اما نادر در خون است. این سلول‌ها معمولاً دارای دانه‌های (گرانول‌های) درشت و تیره‌رنگ با طیف بنفش مایل به آبی هستند که در بسیاری از موارد هسته را می‌پوشانند. حضور این کلاس در مجموعه داده برای آموزش مدل در تشخیص بافت‌های پرگرانول و تمایز آن‌ها از سایر سلول‌ها اهمیت ویژه‌ای دارد.

(۲) اریتروبلست^۴: نمایانگر گلبول‌های قرمز نابالغی است که هنوز دارای هسته می‌باشند، در حالی که گلبول‌های قرمز بالغ فاقد هسته هستند. مشاهده اریتروبلست در خون محیطی بزرگسالان پدیده‌ای غیرطبیعی بوده و می‌تواند نشانه‌ای از اختلالات خونی، کم‌خونی شدید یا درگیری مغز استخوان باشد. تشخیص صحیح این سلول‌ها برای جلوگیری از اشتباه با گلبول‌های سفید کوچک، نظیر لنفوسیت‌ها، اهمیت بالینی بالایی دارد.

(۳) مونوسیت^۵: بزرگ‌ترین نوع گلبول سفید طبیعی در خون محسوب می‌شود. این سلول‌ها دارای هسته‌ای بزرگ، لوب‌دار و معمولاً به شکل نعل اسب یا کلیه هستند. سیتوپلاسم آن‌ها اغلب به رنگ خاکستری-آبی بوده و فاقد دانه یا دارای دانه‌های بسیار ریز است. تشخیص دقیق مونوسیت‌ها در افتراق برخی زیرگونه‌های لوسمی، به‌ویژه لوسمی‌های مونوسیتی، نقش مهمی ایفا می‌کند.

^۱ Balanced Distribution

^۲ Bias

^۳ Basophil

^۴ Erythroblast

^۵ Monocyte

۴) میلوبلاست^۱: این کلاس مهم‌ترین گروه هدف در تشخیص سرطان محسوب می‌شود. میلوبلاست‌ها سلول‌های بسیار نابالغ و پیش‌ساز گلبول‌های سفید هستند که در شرایط طبیعی تنها در مغز استخوان مشاهده می‌شوند. حضور آن‌ها در خون محیطی شاخص اصلی لوسمی حاد میلوئیدی^۲ (AML) است. این سلول‌ها معمولاً اندازه‌ای بزرگ، هسته‌ای حجیم با کروماتین ظریف و هستک‌های^۳ مشخص دارند و تشخیص آن‌ها محور اصلی بخش تشخیص سرطان^۴ در نام مجموعه داده است.

۵) نوتروفیل سگمانته^۵: که با عنوان نوتروفیل قطعه‌قطعه شده^۶ نیز شناخته می‌شود، فرم بالغ و طبیعی نوتروفیل‌ها است. هسته این سلول‌ها چندلوبی (معمولاً شامل ۳ تا ۵ لوب) بوده که توسط رشته‌های نازک به یکدیگر متصل شده‌اند. نوتروفیل‌ها فراوان‌ترین گلبول‌های سفید خون هستند و مدل باید بتواند این سلول‌های سالم و بالغ را به‌درستی از سلول‌های نابالغ یا بدخیم، به‌ویژه میلوبلاست‌ها، تمایز دهد.

۳-۲-۴- ویژگی‌های فنی و مزایای این نسخه

این مجموعه داده علاوه بر ارتباط مستقیم با مسئله‌ی تشخیص بیماری‌های خونی، از نظر ساختار آماری و تنوع مورفولوژیکی دارای ویژگی‌هایی است که آن را به گزینه‌ای مناسب برای ارزیابی مدل‌های یادگیری عمیق، به‌ویژه در چارچوب یادگیری خودنظارتی، تبدیل می‌کند. در ادامه، مهم‌ترین مزایا و ویژگی‌های فنی این داده‌ها مورد بررسی قرار می‌گیرد.

- توازن کلاسی: همان‌گونه که پیش‌تر اشاره شد، وجود ۱۰۰۰ تصویر برای هر یک از کلاس‌ها موجب می‌شود توزیع داده‌ها کاملاً متوازن باشد. این ویژگی سبب می‌شود معیار صحت^۷ به‌عنوان یکی از شاخص‌های اصلی ارزیابی عملکرد مدل، معتبر و قابل اتکا بوده و نتایج به‌دست‌آمده دچار سوگیری ناشی از عدم تعادل کلاسی نشوند.

- تنوع ریخت‌شناسی: انتخاب این پنج کلاس سلولی از نظر ریخت‌شناسی بسیار هدفمند بوده و چالش‌های اصلی پردازش تصویر خون را پوشش می‌دهد، از جمله:

۱) تمایز سلول‌های دارای دانه‌های سیتوپلاسمی (مانند بازوفیل) از سلول‌های فاقد دانه.

۲) افتراق سلول‌های قرمز هسته‌دار نابالغ (اریتروبلات) از گلبول‌های سفید.

¹ Myeloblast

² Acute Myeloid Leukemia

³ Nucleoli

⁴ Cancer Detection

⁵ Seg_neutrophil

⁶ Segmented Neutrophil

⁷ Accuracy


۳) تشخیص سلول‌های بدخیم و نابالغ (میلوبلاست) از سلول‌های سالم و بالغ (نوتروفیل سگمانته و مونوسیت).

۳-۲-۵- اندازه‌ی دیتاست و چالش‌ها

در مقایسه با مجموعه‌داده‌های بزرگ حوزه‌ی بینایی ماشین، مانند ImageNet، این مجموعه‌داده از نظر تعداد نمونه نسبتاً کوچک محسوب می‌شود. این ویژگی پیامدهای مهمی برای فرآیند آموزش مدل‌های یادگیری عمیق به همراه دارد که از جمله آن‌ها می‌توان به افزایش ریسک بیش‌برازش، محدودیت در به‌کارگیری مستقیم یادگیری نظارت‌شده و کاهش توان تعمیم‌پذیری مدل اشاره کرد. در چنین شرایطی، بهره‌گیری از داده‌های بدون برچسب و استفاده از راهبردهای یادگیری خودنظارتی به یک ضرورت تبدیل می‌شود.

از سوی دیگر، کار با مجموعه‌داده‌های کوچک، اهمیت انتخاب معماری‌های پایدار و به‌کارگیری تکنیک‌های منظم‌سازی^۱ مناسب را دوچندان می‌کند. بر این اساس، استفاده از چارچوب خودرمزگذار ماسک‌شده در مرحله‌ی پیش‌آموزش، انتخابی منطقی و مبتنی بر اصول یادگیری بازنمایی محسوب می‌شود که امکان استخراج ویژگی‌های معنادار و تعمیم‌پذیر را پیش از ورود به مرحله‌ی یادگیری نظارت‌شده فراهم می‌سازد (شکل ۳-۱).

^۱ Regularization



شکل ۳-۱ اندازه دیتاست و فراوانی هر کلاس

هر یک از پنج کلاس سلولی موجود در این مجموعه داده شامل دقیقاً ۱۰۰۰ نمونه است که بیانگر تعادل کامل داده‌ها در سطح کلاس‌ها می‌باشد. این ویژگی نشان می‌دهد که مجموعه داده فاقد هرگونه عدم تعادل کلاسی^۱ است. نمودار ستونی توزیع کلاس‌ها نیز این تعادل را به صورت بصری تأیید می‌کند؛ به گونه‌ای که ارتفاع تمامی ستون‌ها یکسان بوده و هیچ کدام از کلاس‌ها غالب یا کم‌نمونه نیستند.

از دیدگاه یادگیری عمیق، وجود چنین توازن اهمیت بالایی دارد، زیرا موجب می‌شود معیارهای ارزیابی عملکرد مدل، از جمله صحت، دقت^۲، بازخوانی^۳ و امتیاز F1، دچار سوگیری به نفع کلاس‌های پرتعداد نشوند و ارزیابی عملکرد مدل به صورت منصفانه و واقع‌بینانه‌تری انجام گیرد.

شکل ۳-۲ نمونه‌ای تصادفی از هر یک از پنج کلاس سلول‌های خونی شامل بازوفیل، اریتروبلست، مونوسیت، میلوبلاست و نوتروفیل سگمانته را نمایش می‌دهد و به عنوان یک بررسی بصری اولیه، کیفیت و ماهیت مجموعه داده‌ی مورد استفاده را تأیید می‌کند. همان گونه که مشاهده می‌شود، تصاویر از نظر کیفیت رنگ آمیزی،

^۱ Class Imbalance

^۲ Precision


^۳ Recall

وضوح هسته و ساختار سیتوپلاسم در سطح مناسبی قرار دارند و فاقد نویزهای شدید یا آرتیفکت‌های مخرب هستند.

از منظر مورفولوژیکی، تفاوت‌های بین کلاسی مشخصی در تصاویر قابل تشخیص است. به عنوان مثال، نوتروفیل‌های سگمانته به واسطه‌ی هسته‌ی چندلوبی به وضوح از سایر کلاس‌ها متمایز می‌شوند، در حالی که مونوسیت‌ها و میلو بلاست‌ها شباهت‌های قابل توجهی از نظر اندازه سلول و تراکم کروماتین هسته دارند. همچنین، بازوفیل‌ها به دلیل وجود گرانول‌های تیره و متراکم در سیتوپلاسم و اریترو بلاست‌ها به واسطه‌ی نسبت بالای هسته به سیتوپلاسم، به صورت مشخص قابل شناسایی هستند.

وجود این شباهت‌های بین کلاسی، به ویژه میان مونوسیت‌ها و میلو بلاست‌ها، نشان می‌دهد که مسئله‌ی طبقه‌بندی صرفاً با اتکا به ویژگی‌های سطحی قابل حل نیست و نیازمند یادگیری بازنمایی‌های عمیق و غنی از داده‌ها است. بر این اساس، استفاده از پیش‌آموزش خودنظارتی مبتنی بر چارچوب خودرمزگذار ماسک‌شده‌ی تمام کانولوشنی (FCMAE) و معماری ConvNeXt V2 به خوبی توجه می‌شود، زیرا مدل باید قادر باشد الگوهای ساختاری ظریف و وابستگی‌های مکانی پیچیده را به طور مؤثر از تصاویر استخراج کند.

Random Sample from Each Class



شکل ۳-۲ نمونه‌ی تصاویری از هر کلاس

۳-۲-۶- پیش‌پردازش داده‌ها

در این پروژه، مراحل پیش‌پردازش داده‌ها به منظور آماده‌سازی تصاویر برای آموزش مدل ConvNeXt V2 شامل موارد زیر است:

- (۱) تغییر اندازه تصاویر: تمامی تصاویر به ابعاد ثابت و سازگار با ورودی معماری ConvNeXt تغییر اندازه داده می‌شوند تا امکان پردازش یکنواخت داده‌ها فراهم گردد.
- (۲) نرمال‌سازی شدت پیکسل‌ها: مقادیر شدت پیکسل‌ها نرمال‌سازی می‌شوند تا پایداری فرآیند آموزش افزایش یافته و همگرایی مدل بهبود یابد.

۳) افزایش داده^۱ حداقلی: مطابق با تنظیمات پیشنهادی در مقاله ConvNeXt V2، از راهبردهای افزایش داده‌ی حداقلی استفاده شده است [۹]. در این راستا، تنها روش Random Resized Crop به‌کار گرفته شده و از اعمال افزایش‌های داده‌ی شدید اجتناب شده است تا الگوهای حساس و معنادار پزشکی موجود در تصاویر حفظ شوند.

۳-۲-۷- دلیل انتخاب دیتاست برای این پروژه

انتخاب مجموعه‌داده‌ی Blood Cell Images for Cancer Detection بر اساس معیارهای زیر صورت گرفته است:

- ارتباط مستقیم با مسئله‌ی تشخیص پزشکی واقعی و کاربرد بالینی.
- حجم محدود داده‌ها و مناسب بودن برای ارزیابی روش‌های یادگیری خودنظارتی.
- وجود تفاوت‌های ظریف تصویری^۲ میان کلاس‌ها.
- امکان بررسی عملکرد معماری ConvNeXt V2 در حوزه‌ای فراتر از مجموعه‌داده‌های عمومی نظیر ImageNet.
- هم‌راستایی با اهداف آموزشی درس و الزام به پیاده‌سازی مستقل همراه با ایجاد تغییرات مؤثر در معماری و فرآیند آموزش.

در مجموع، مجموعه‌داده‌ی Blood Cell Images for Cancer Detection یک مجموعه‌داده‌ی تصویری پزشکی با چالش‌های واقعی، حجم محدود و ساختاری مناسب برای یادگیری خودنظارتی محسوب می‌شود. وجود سلول‌های بلاست بدخیم مرتبط با لوسمی‌های حاد، در کنار سلول‌های سالم و بالغ، این مجموعه‌داده را به بستری ایده‌آل برای ارزیابی توانایی معماری ConvNeXt V2 در یادگیری بازنمایی‌های معنادار و قابل انتقال به وظیفه‌ی طبقه‌بندی تصاویر پزشکی تبدیل می‌کند.

۳-۳- معرفی معماری ConvNeXt V2

۳-۳-۱- یادگیری خودنظارتی و مدل‌سازی تصویر ماسک‌شده

یادگیری خودنظارتی^۳ در سال‌های اخیر به یکی از مهم‌ترین رویکردها برای یادگیری بازنمایی‌های عمومی از داده‌های تصویری تبدیل شده است، به‌ویژه در شرایطی که داده‌های برچسب‌خورده محدود، پرهزینه یا دشوار برای

¹ Data Augmentation

² Fine-Grained Visual Patterns

³ Self-Supervised Learning

تهیه هستند. در این چارچوب، مدل با تعریف یک وظیفه‌ی پیش‌متنی، بدون استفاده از برجسب‌های انسانی، به استخراج ساختارها و الگوهای درونی داده‌ها می‌پردازد.

یکی از موفق‌ترین خانواده‌های روش‌های یادگیری خودنظارتی، مدل‌های مبتنی بر مدل‌سازی تصویر ماسک‌شده^۱ هستند. در این رویکرد، بخش قابل‌توجهی از تصویر ورودی به‌صورت تصادفی ماسک می‌شود و مدل موظف است با تکیه بر اطلاعات زمینه‌ای باقی‌مانده، نواحی حذف‌شده را بازسازی کند. این فرآیند مدل را وادار می‌کند تا به‌جای تمرکز بر ویژگی‌های سطحی، روابط ساختاری و معنایی عمیق‌تری را از داده‌ها بیاموزد.

موفقیت چشم‌گیر مدل‌سازی تصویر ماسک‌شده در معماری‌های مبتنی بر ترنسفورمر، به‌ویژه در چارچوب خودرمزگذارهای ماسک‌شده (MAE)، انگیزه‌ی اصلی معرفی ConvNeXt V2 بوده است. هدف این معماری، بررسی امکان به‌کارگیری مؤثر مدل‌سازی تصویر ماسک‌شده در شبکه‌های عصبی کانولوشنی و بهره‌گیری هم‌زمان از مزایای یادگیری خودنظارتی و کارایی محاسباتی این شبکه‌ها است.

۳-۲-۳- چالش مدل‌سازی تصویر ماسک‌شده در شبکه‌های کانولوشنی

با وجود موفقیت چشم‌گیر مدل‌سازی تصویر ماسک‌شده در معماری‌های مبتنی بر ترنسفورمر، به‌کارگیری این چارچوب در شبکه‌های عصبی کانولوشنی با چالش‌های اساسی همراه است. برخلاف ترنسفورمرها که تصویر ورودی را به مجموعه‌ای از پچ‌های مستقل تجزیه می‌کنند، شبکه‌های کانولوشنی بر ساختار دوبعدی پیوسته‌ی تصویر متکی هستند.

این ویژگی موجب می‌شود که کانولوشن‌های استاندارد بتوانند اطلاعات مربوط به نواحی ماسک‌شده را از طریق همسایگی فضایی به نواحی قابل مشاهده منتقل کنند؛ پدیده‌ای که در مقاله با عنوان نشت اطلاعات^۲ از آن یاد می‌شود [۹]. در چنین شرایطی، مدل قادر است بدون نیاز به درک معنایی عمیق از تصویر و صرفاً از طریق کپی‌برداری محلی اطلاعات، نواحی حذف‌شده را بازسازی کند. این مسئله باعث می‌شود فرآیند یادگیری نمایش‌های غنی و قابل انتقال عملاً تضعیف شده و هدف اصلی یادگیری خودنظارتی محقق نشود.

نویسندگان مقاله نشان می‌دهند که همین پدیده‌ی نشت اطلاعات، عامل اصلی عملکرد ضعیف نسخه‌ی اولیه^۳ ConvNeXt در چارچوب خودرمزگذار ماسک‌شده بوده و ضرورت بازطراحی معماری کانولوشنی برای سازگاری مؤثر با یادگیری خودنظارتی مبتنی بر ماسک‌گذاری را برجسته می‌سازد [۹].

^۱ Masked Image Modeling

^۲ Information Leakage

^۳ ConvNeXt V1

۳-۳-۳- چارچوب خودرمزگذار ماسک‌شده‌ی تمام‌کانولوشنی (FCMAE)

به‌منظور رفع چالش نشت اطلاعات در فرآیند مدل‌سازی تصویر ماسک‌شده، در مقاله‌ی ConvNeXt V2 چارچوبی جدید با عنوان خودرمزگذار ماسک‌شده‌ی تمام‌کانولوشنی^۱ (FCMAE) معرفی شده است که به‌طور خاص برای شبکه‌های عصبی کانولوشنی طراحی شده است [۹]. ایده‌ی اصلی FCMAE حفظ ماهیت کاملاً کانولوشنی مدل، در عین جلوگیری از نشت اطلاعات و ایجاد یک سیگنال یادگیری مؤثر در مرحله‌ی پیش‌آموزش است. این چارچوب از سه مؤلفه‌ی اصلی تشکیل شده است: نخست، یک استراتژی ماسک‌گذاری سازگار با معماری ConvNeXt که امکان اعمال ماسک‌های گسترده بدون نشت اطلاعات را فراهم می‌کند؛ دوم، یک رمزگذار کانولوشنی مبتنی بر پردازش داده‌های تنک^۲ که تنها بر روی نواحی قابل مشاهده تصویر عمل می‌کند؛ و سوم، یک رمزگشای سبک و نامتقارن که صرفاً وظیفه‌ی تولید سیگنال خطای بازسازی را بر عهده داشته و در مرحله‌ی یادگیری نظارت‌شده نهایی مورد استفاده قرار نمی‌گیرد.

۳-۳-۴- استراتژی ماسک‌گذاری در FCMAE

در چارچوب خودرمزگذار ماسک‌شده‌ی تمام‌کانولوشنی (FCMAE)، از یک استراتژی ماسک‌گذاری تصادفی با نرخ ۰/۶ استفاده می‌شود. با توجه به ساختار سلسله‌مراتبی معماری ConvNeXt، که در آن وضوح نقشه‌های ویژگی به‌صورت مرحله‌ای کاهش می‌یابد، ماسک در آخرین مرحله‌ی رمزگذار تولید شده و سپس به‌صورت بازگشتی به مراحل با وضوح بالاتر منتقل می‌شود.

در عمل، این فرآیند با حذف تصادفی ۶۰ درصد از پیکسل‌های 32×32 تصویر ورودی پیاده‌سازی می‌گردد. چنین طراحی‌ای موجب می‌شود فرآیند ماسک‌گذاری با سازوکار کاهش ابعاد^۳ در ConvNeXt هماهنگ بوده و از بروز ناهماهنگی‌های ساختاری در لایه‌ها و مراحل مختلف رمزگذار جلوگیری شود. در نتیجه، مدل قادر خواهد بود سیگنال یادگیری مؤثر و پایداری را در مرحله‌ی پیش‌آموزش خودنظارتی دریافت کند.

۳-۳-۵- طراحی رمزگذار بر اساس دیدگاه داده‌های تنک

نوآوری کلیدی مقاله در طراحی رمزگذار، اتخاذ دیدگاه «داده‌های تنک» نسبت به تصویر ماسک‌شده است. در این رویکرد، تصویر ماسک‌شده به‌صورت یک آرایه‌ی دوبعدی تنک از پیکسل‌ها در نظر گرفته می‌شود؛ رویکردی که از

¹ Fully Convolutional Masked Autoencoder

² Sparse

³ Downsampling

نظر مفهومی شباهت زیادی به یادگیری بر روی ابرنقاط سه‌بعدی دارد [۹]. بر این اساس، رمزگذار تنها بر روی پیکسل‌ها و نواحی قابل مشاهده عمل می‌کند و هیچ‌گونه محاسبه‌ای بر روی نواحی ماسک‌شده انجام نمی‌دهد. به‌منظور تحقق این هدف، در مرحله‌ی پیش‌آموزش، کانولوشن‌های متراکم استاندارد معماری ConvNeXt با کانولوشن تنک زیرمانیفولد^۱ جایگزین می‌شوند. این نوع لایه‌ها تنها در مکان‌هایی که داده‌ی ورودی وجود دارد فعال بوده و از انتقال اطلاعات از نواحی ماسک‌شده به نواحی قابل مشاهده جلوگیری می‌کنند. بدین ترتیب، پدیده‌ی نشت اطلاعات به‌طور مؤثری مهار می‌شود.

در مرحله‌ی تنظیم نهایی^۲، این لایه‌ها بدون نیاز به اعمال تغییرات خاص، مجدداً به کانولوشن‌های متراکم استاندارد بازگردانده می‌شوند. نتایج تجربی ارائه‌شده در مقاله نشان می‌دهد که حذف کانولوشن‌های تنک در مرحله‌ی پیش‌آموزش منجر به افت قابل‌توجه صحت در مرحله‌ی تنظیم نهایی می‌شود که این امر نقش کلیدی این مؤلفه را در یادگیری بازنمایی‌های غنی و قابل انتقال برجسته می‌سازد [۹].

۳-۳-۶- طراحی رمزگشا و هدف بازسازی

در مقابل رمزگذار سنگین و سلسله‌مراتبی، رمزگشا در چارچوب خودرمزگذار ماسک‌شده‌ی تمام کانولوشنی (FCMAE) به‌صورت بسیار سبک طراحی شده است و تنها شامل یک بلوک ساده از معماری ConvNeXt با بُعد ویژگی ۵۱۲ می‌باشد. این عدم تقارن در طراحی رمزگذار-رمزگشا به‌صورت آگاهانه اعمال شده است، زیرا هدف اصلی مرحله‌ی پیش‌آموزش، یادگیری بازنمایی‌های قدرتمند و تعمیم‌پذیر در رمزگذار است و رمزگشا صرفاً برای تولید سیگنال خطای بازسازی مورد استفاده قرار می‌گیرد.

مطالعات حذف مؤلفه^۳ ارائه‌شده در مقاله نشان می‌دهد که به‌کارگیری رمزگشاهای پیچیده‌تر، نظیر معماری‌های مبتنی بر U-Net یا ترنسفورمر، بهبود معناداری در صحت مرحله‌ی تنظیم نهایی ایجاد نمی‌کند، در حالی که هزینه‌ی محاسباتی مرحله‌ی پیش‌آموزش را به‌طور قابل‌توجهی افزایش می‌دهد [۹].

هدف بازسازی در FCMAE، نسخه‌ی نرمال‌شده‌ی پچ‌محور از تصویر اصلی است و تابع هزینه مورد استفاده از نوع میانگین مربعات خطا^۴ می‌باشد که صرفاً بر روی نواحی ماسک‌شده اعمال می‌شود. این طراحی موجب تمرکز فرآیند یادگیری بر بازسازی اطلاعات از دست‌رفته و تقویت کیفیت بازنمایی‌های استخراج‌شده در رمزگذار می‌گردد.

¹ Submanifold Sparse Convolution

² Fine-Tuning

³ Ablation Study


⁴ Mean Squared Error

۷-۳-۳- تحلیل پدیده فروپاشی ویژگی در ConvNeXt V1

با وجود طراحی چارچوب خودرمزگذار ماسک‌شده‌ی تمام‌کانولوشنی (FCMAE)، نویسندگان مقاله مشاهده می‌کنند که معماری ConvNeXt V1 در این چارچوب دچار پدیده‌ای موسوم به فروپاشی ویژگی^۱ می‌شود [۹]. در این وضعیت، کانال‌های مختلف یک لایه، بازنمایی‌هایی بسیار مشابه تولید کرده و تنوع ویژگی‌های آموخته‌شده به‌طور قابل‌توجهی کاهش می‌یابد؛ امری که منجر به تضعیف قدرت تمایز مدل می‌شود.

به‌منظور تحلیل کمی این پدیده، معیاری مبتنی بر میانگین فاصله‌ی کسینوسی بین کانال‌ها تعریف شده است، به‌گونه‌ای که کاهش مقدار این معیار نشان‌دهنده‌ی هم‌گرایی بیش از حد پاسخ کانال‌ها و افت تنوع بازنمایی‌ها است. نتایج تجربی ارائه‌شده در شکل ۳-۳ نشان می‌دهد که ConvNeXt V1 آموزش‌دیده در چارچوب FCMAE دچار فروپاشی شدید ویژگی در لایه‌های عمیق شبکه می‌شود، در حالی که مدل‌های مبتنی بر ترنسفورمر، نظیر ViT، چنین رفتاری را از خود نشان نمی‌دهند [۹].

این تحلیل نشان می‌دهد که صرف به‌کارگیری چارچوب FCMAE برای جلوگیری از نشت اطلاعات کافی نبوده و اصلاحات بیشتری در طراحی معماری کانولوشنی برای حفظ تنوع بازنمایی‌ها ضروری است.



شکل ۳-۳ تحلیل فاصله کسینوسی ویژگی.

¹ Feature Collapse

۳-۳-۸- نرمال سازی پاسخ سراسری (GRN)

برای مقابله با مشکل فروپاشی ویژگی، در مقاله ی ConvNeXt V2 لایه ای جدید با عنوان نرمال سازی پاسخ سراسری^۱ (GRN) معرفی شده است [۹]. هدف اصلی این لایه، افزایش رقابت میان کانال های ویژگی و حفظ تنوع بازنمایی ها در طول فرآیند یادگیری شبکه می باشد.

در لایه GRN، ابتدا پاسخ هر کانال با استفاده از یک تابع تجمیع سراسری مبتنی بر نرم L_2 محاسبه می شود. سپس، با انجام یک نرمال سازی تقسیم پذیر نسبت به مجموع پاسخ کانال ها، اهمیت نسبی هر کانال تعیین شده و در ادامه، پاسخ کانال ها بر اساس این ضرایب به صورت تطبیقی کالیبره می گردد. این سازوکار باعث می شود کانال هایی که اطلاعات معنادارتری ارائه می دهند، نقش پررنگ تری در بازنمایی نهایی ایفا کنند.

به منظور بهبود پایداری آموزش و افزایش انعطاف پذیری مدل، دو پارامتر قابل یادگیری γ و β به همراه یک اتصال باقیمانده^۲ به این ساختار افزوده شده است. این طراحی، بدون ایجاد سربار پارامتری قابل توجه، موجب افزایش تنوع پاسخ های کانالی شده و نقش مؤثری در جلوگیری از فروپاشی ویژگی در معماری ConvNeXt V2 ایفا می کند.

۳-۳-۹- معماری ConvNeXt V2

با ادغام لایه نرمال سازی پاسخ سراسری (GRN) در بلوک های ConvNeXt و حذف مؤلفه ی مقیاس دهی لایه ای^۳ که در حضور GRN زائد تشخیص داده شده است، معماری جدیدی با نام ConvNeXt V2 معرفی می شود. این بازطراحی ساختاری، به طور خاص با هدف سازگاری شبکه های کانولوشنی با چارچوب یادگیری خودنظارتی مبتنی بر مدل سازی تصویر ماسک شده انجام شده است.

نتایج تجربی ارائه شده در مقاله نشان می دهد که ConvNeXt V2 آموزش دیده در چارچوب خودرمزگذار ماسک شده ی تمام کانولوشنی (FCMAE) نه تنها مشکل فروپاشی ویژگی را به صورت مؤثر برطرف می کند، بلکه در بسیاری از تنظیمات، عملکردی بهتر از نسخه های صرفاً آموزش دیده به صورت نظارت شده و حتی نسخه هایی با پیش آموزش طولانی مدت ارائه می دهد [۹].

تحلیل فاصله ی کسینوسی میان بازنمایی های ویژگی نشان می دهد که رفتار یادگیری ConvNeXt V2 در چارچوب مدل سازی تصویر ماسک شده شباهت قابل توجهی به معماری های مبتنی بر ترنسفورمر، نظیر ViT، پیدا کرده و تنوع بازنمایی ها در تمامی لایه های شبکه حفظ می شود. در مجموع، نتایج این مقاله نشان می دهد که

¹ Global Response Normalization

² Residual Connection

³ LayerScale

به کارگیری مؤثر مدل سازی تصویر ماسک شده در شبکه های کانولوشنی تنها در صورتی امکان پذیر است که طراحی معماری شبکه و چارچوب یادگیری خودنظارتی به صورت هم زمان و هماهنگ انجام گیرد [۹].

۳-۴- پیاده سازی پروژه و آماده سازی محیط اجرا

در این بخش، مراحل پیاده سازی پروژه و آماده سازی محیط اجرا تشریح می شود. در گام نخست، کتابخانه ها و ابزارهای نرم افزاری مورد نیاز برای پیاده سازی مدل، پردازش داده ها و انجام فرآیند آموزش و ارزیابی به محیط برنامه نویسی وارد می شوند. انتخاب این کتابخانه ها به گونه ای انجام شده است که ضمن پشتیبانی کامل از پیاده سازی معماری ConvNeXt V2 و چارچوب یادگیری خودنظارتی، امکان بازتولیدپذیری و اجرای پایدار آزمایش ها نیز فراهم گردد (شکل ۳-۴).

```
import os
import copy
import torch
import torch.nn as nn
import torch.nn.functional as F
import torch.optim as optim
from torch.utils.data import Dataset, DataLoader, random_split
from torchvision import transforms, datasets
from torchvision.utils import make_grid
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.metrics import classification_report, confusion_matrix, roc_curve, auc
from sklearn.preprocessing import label_binarize
from itertools import cycle
import kagglehub
from tqdm import tqdm
import numpy as np

plt.style.use('ggplot')
```

شکل ۳-۴ وارد کردن کتابخانه های مورد نظر به محیط

در ابتدای فاز پیاده سازی، محیط محاسباتی پروژه با وارد کردن مجموعه ای از کتابخانه های استاندارد یادگیری عمیق، پردازش تصویر و ارزیابی مدل مقداردهی اولیه می شود. این مرحله نقش زیرساختی داشته و تضمین می کند که تمامی مراحل بعدی، شامل پیش پردازش داده ها، آموزش خودنظارتی، تنظیم نهایی و ارزیابی نهایی، در یک چارچوب یکپارچه، پایدار و قابل بازتولید انجام شوند.

در این پروژه، هسته اصلی پیاده سازی بر پایه ی کتابخانه PyTorch بنا شده است. ماژول torch و زیر کتابخانه ی torch.nn برای تعریف معماری شبکه های عصبی، از جمله رمزگذار مبتنی بر ConvNeXt و رمزگشای سبک، مورد

استفاده قرار می‌گیرند. همچنین، `torch.nn.functional` به‌منظور دسترسی به توابع سطح پایین‌تر، نظیر توابع فعال‌سازی و پیاده‌سازی محاسبات سفارشی تابع هزینه، به کار گرفته شده است. به‌منظور بهینه‌سازی فرآیند آموزش، از کتابخانه‌ی `torch.optim` و الگوریتم‌های بهینه‌سازی نظیر AdamW استفاده شده است که با فلسفه‌ی آموزش پایدار در چارچوب مدل‌سازی تصویر ماسک‌شده هم‌خوانی دارد.

برای مدیریت داده‌ها، از ماژول `torch.utils.data` و کلاس‌های `Dataset`، `DataLoader` و `random_split` استفاده شده است. این انتخاب امکان پیاده‌سازی دقیق راهبرد تقسیم داده‌ها را فراهم می‌کند؛ به‌گونه‌ای که مجموعه‌داده به زیرمجموعه‌های آموزش خودنظارتی، تنظیم نهایی، اعتبارسنجی و آزمون نهایی با استفاده از Seed ثابت تقسیم می‌شود. این موضوع از نظر علمی اهمیت بالایی دارد، زیرا مقایسه‌ی منصفانه‌ی نتایج با تنظیمات گزارش‌شده در مقاله ConvNeXt V2 تنها در صورت بازتولیدپذیری فرآیند تقسیم داده‌ها امکان‌پذیر است [۹].

در ادامه، کتابخانه‌ی `torchvision` برای دو هدف اصلی مورد استفاده قرار گرفته است. بخش `transforms` برای پیاده‌سازی مراحل پیش‌پردازش تصویری نظیر تغییر اندازه، نرمال‌سازی و افزایش داده به کار می‌رود؛ به‌گونه‌ای که در مرحله‌ی یادگیری خودنظارتی از افزایش داده‌ی حداقلی (مطابق چارچوب FCMAE) و در مرحله‌ی تنظیم نهایی از افزایش داده‌ی غنی‌تر استفاده می‌شود. همچنین، ماژول‌های `datasets` و `make_grid` برای بارگذاری مجموعه‌داده‌ی Blood Cell Images و نمایش نمونه‌های تصویری به‌منظور بررسی کیفی داده‌ها مورد استفاده قرار گرفته‌اند.

به‌منظور تحلیل و مصورسازی نتایج، کتابخانه‌های `matplotlib` و `seaborn` به محیط اجرا افزوده شده‌اند. این ابزارها امکان ترسیم ماتریس درهم‌ریختگی، منحنی‌های ROC و نمودارهای مقایسه‌ای را فراهم می‌کنند که در ارزیابی نهایی عملکرد مدل نقش کلیدی دارند. به‌طور خاص، تنظیم سبک ترسیم نمودارها با استفاده از `plt.style.use('ggplot')` موجب یکنواختی بصری و افزایش خوانایی نمودارها در گزارش نهایی می‌شود.

در بخش ارزیابی کمی، از توابع `classification_report`، `confusion_matrix`، `roc_curve` و `auc` از کتابخانه‌ی `sklearn.metrics` استفاده شده است. این معیارها به‌طور مستقیم با هدف پروژه، یعنی بررسی توان تمایز مدل میان سلول‌های بلاست بدخیم و سلول‌های سالم، هم‌راستا هستند. علاوه بر این، ماژول `label_binarize` برای پیاده‌سازی تحلیل ROC چندکلاسه به کار رفته است که در مسائل تشخیص سرطان خون از اهمیت ویژه‌ای برخوردار است.

برای مدیریت تکرار روی کلاس‌ها و ترسیم منحنی‌های ROC چندکلاسه، از ماژول `itertools.cycle` استفاده شده است. همچنین، کتابخانه‌ی `numpy` به‌عنوان ابزار پایه‌ی محاسبات عددی در تمامی مراحل پردازش داده‌ها و

تحلیل خروجی‌ها مورد استفاده قرار گرفته است. کتابخانه‌ی tqdm نیز برای نمایش نوار پیشرفت در حلقه‌های آموزش به کار رفته که به‌ویژه در آموزش خودنظارتی چندایپوکی، دید مناسبی از روند همگرایی مدل ارائه می‌دهد. در نهایت، کتابخانه‌ی kagglehub برای دسترسی و بارگذاری مجموعه‌داده‌ی Blood Cell Images از پلتفرم Kaggle مورد استفاده قرار گرفته است. این انتخاب امکان یکپارچه‌سازی کل فرآیند، از دریافت داده تا آموزش و ارزیابی مدل، را در یک نوت‌بوک واحد فراهم کرده و فرآیند بازتولید نتایج آزمایش‌ها را به‌طور قابل‌توجهی تسهیل می‌کند.

۳-۵- بارگذاری مجموعه‌داده و پیکربندی محیط محاسباتی

۳-۵-۱- دریافت خودکار مجموعه‌داده و شناسایی ساختار داده‌ها

در این مرحله، مجموعه‌داده‌ی مورد استفاده در پروژه، یعنی Blood Cell Images for Cancer Detection، به‌صورت خودکار از پلتفرم Kaggle دریافت می‌شود. برای این منظور، از کتابخانه‌ی kagglehub استفاده شده است که امکان دانلود مستقیم مجموعه‌داده‌ها را بدون نیاز به مدیریت دستی فایل‌ها فراهم می‌کند. این رویکرد، علاوه بر ساده‌سازی فرآیند اجرا و کاهش خطاهای انسانی، بازتولیدپذیری کامل آزمایش‌ها را تضمین می‌کند؛ به‌گونه‌ای که در هر بار اجرای کد، نسخه‌ای یکسان و مشخص از داده‌ها دریافت شده و تمامی مراحل بعدی آموزش و ارزیابی بر پایه‌ی همان ساختار داده‌ای انجام می‌پذیرد. این ویژگی از منظر پژوهشی اهمیت بالایی دارد، زیرا امکان تکرارپذیری نتایج و مقایسه‌ی منصفانه‌ی عملکرد مدل را فراهم می‌سازد (شکل ۳-۵).

```

# =====
# 1. SETUP & DATASET DOWNLOAD
# =====
print(" Downloading Blood Cell Dataset...")

try:
    path = kagglehub.dataset_download("sumithsingh/blood-cell-images-for-cancer-detection")

    def find_image_root(start_path):
        for root, dirs, files in os.walk(start_path):
            if len(dirs) > 0:
                check_sub = os.path.join(root, dirs[0])
                if os.path.isdir(check_sub) and any(f.lower().endswith('.png', '.jpg', '.jpeg') for f in os.listdir(check_sub)):
                    return root
        return start_path

    data_root = find_image_root(path)
    CLASSES_NAMES = sorted([d for d in os.listdir(data_root) if os.path.isdir(os.path.join(data_root, d))])
    print(f" Dataset ready at: {data_root}")
    print(f" Classes found: {CLASSES_NAMES}")

except Exception as e:
    print(f" Error downloading dataset: {e}")
    raise RuntimeError("Could not set up the dataset.")

device = torch.device("cuda" if torch.cuda.is_available() else "cpu")
print(f" Device being used: {device}")

```

شکل ۳-۵ بارگیری داده و بارگذاری آن

پس از دانلود مجموعه داده، یکی از چالش‌های متداول در کار با دیتاست‌های منتشر شده در پلتفرم Kaggle، ناهمگونی در ساختار پوشه‌ها و مسیرهای ذخیره‌سازی فایل‌ها است. به‌منظور رفع این مسئله، یک تابع کمکی با نام `find_image_root` تعریف شده است که به‌صورت بازگشتی در مسیر دانلودشده پیمایش کرده و نخستین دایرکتوری‌ای را که شامل زیرپوشه‌هایی با فایل‌های تصویری (با پسوند‌های رایج نظیر JPG و PNG) باشد، شناسایی می‌کند. این طراحی موجب می‌شود پیاده‌سازی از وابستگی به یک ساختار پوشه‌ی خاص مستقل بوده و انعطاف‌پذیری کد در مواجهه با نسخه‌های مختلف دیتاست افزایش یابد.

پس از تعیین مسیر تصاویر، کلاس‌های موجود در مجموعه داده به‌صورت خودکار از نام پوشه‌ها استخراج و مرتب‌سازی می‌شوند. این رویکرد تضمین می‌کند که ترتیب کلاس‌ها ثابت بوده و وابسته به ترتیب سیستم فایل یا نحوه‌ی استخراج داده‌ها نباشد. کلاس‌های استخراج‌شده متناظر با سه گروه اصلی داده شامل سلول‌های سرطانی از نوع میلوبلاست‌ها، سلول‌های سرطانی از نوع لنفوبلاست‌ها و سلول‌های نرمال هستند. این تفکیک ساختاری به‌طور مستقیم با هدف پروژه، یعنی تشخیص و تمایز سلول‌های خونی در زمینه‌ی سرطان خون، هم‌راستا می‌باشد.

۳-۵-۲- ملاحظات مهندسی داده و ارتباط با مبانی نظری مقاله

انتخاب این مجموعه داده برای پیاده‌سازی معماری ConvNeXt V2 همراه با چارچوب خودرمزگذار ماسک‌شده‌ی تمام‌کانولوشنی (FCMAE) از منظر مفهومی و مهندسی داده دارای اهمیت بالایی است. تصاویر سلول‌های خونی

شامل بافت‌های ظریف، تغییرات مورفولوژیکی محدود و تفاوت‌های محلی در اندازه و شکل هسته هستند؛ ویژگی‌هایی که تحلیل دقیق آن‌ها نیازمند یادگیری بازنمایی‌های محلی و چندمقیاسی است. این امر با نقاط قوت ذاتی معماری ConvNeXt، که بر استخراج ویژگی‌های مکانی سلسله‌مراتبی متکی است، هم‌خوانی کامل دارد. علاوه بر این، به‌کارگیری یادگیری خودنظارتی مبتنی بر مدل‌سازی تصویر ماسک‌شده به مدل این امکان را می‌دهد که پیش از استفاده از برچسب‌ها، ساختارهای درونی و الگوهای مورفولوژیکی سلول‌ها را به‌صورت غیرنظارتی فرا بگیرد. این رویکرد به‌ویژه در مجموعه‌داده‌های پزشکی با حجم محدود داده‌های برچسب‌دار، نقش مهمی در بهبود کیفیت بازنمایی‌های آموخته‌شده ایفا می‌کند. در نتیجه، انتخاب این دیتاست و راهبرد یادگیری، به‌طور مستقیم با فلسفه‌ی طراحی FCMAE و هدف مقاله ConvNeXt V2 مبنی بر هم‌طراحی معماری کانولوشنی و چارچوب یادگیری خودنظارتی، کاملاً سازگار است [۹].

۳-۵-۳- مدیریت خطا و پایداری اجرای پروژه

به‌منظور افزایش پایداری و اطمینان‌پذیری کد، فرآیند دانلود و آماده‌سازی مجموعه‌داده درون یک بلوک کنترل خطا از نوع try-except قرار داده شده است. در صورت بروز هرگونه خطا، از جمله عدم دسترسی به اینترنت یا بروز مشکل در فرآیند دانلود داده‌ها، یک پیام خطای شفاف و قابل‌فهم چاپ شده و اجرای برنامه به‌صورت ایمن متوقف می‌شود.

این رویکرد از ادامه‌ی اجرای مراحل بعدی پروژه بر روی داده‌های ناقص یا نامعتبر جلوگیری کرده و از منظر مهندسی نرم‌افزار، یک رویه‌ی استاندارد و ضروری برای تضمین صحت نتایج و جلوگیری از بروز خطاهای زنجیره‌ای در فرآیند آموزش و ارزیابی مدل محسوب می‌شود.

۳-۵-۴- پیکربندی سخت‌افزار محاسباتی

در انتهای این مرحله، دستگاه محاسباتی مورد استفاده برای آموزش مدل تعیین می‌شود. با بررسی در دسترس بودن واحد پردازش گرافیکی از طریق تابع `torch.cuda.is_available()`، کد به‌صورت خودکار میان پردازنده‌ی مرکزی (CPU) و پردازنده‌ی گرافیکی (GPU) سویچ می‌کند. این تصمیم‌گیری پویا در پروژه‌های یادگیری عمیق از اهمیت بالایی برخوردار است، زیرا آموزش مراحل خودنظارتی، به‌ویژه در چارچوب خودرمزگذار ماسک‌شده‌ی تمام‌کانولوشنی (FCMAE)، از نظر محاسباتی پرهزینه بوده و استفاده از GPU می‌تواند زمان آموزش را به‌طور چشمگیری کاهش دهد.

علاوه بر این، چاپ دستگاه انتخاب‌شده در خروجی برنامه به افزایش شفافیت فرآیند اجرا و مستندسازی دقیق آزمایش‌ها کمک می‌کند و امکان بازتولید نتایج در محیط‌های محاسباتی مختلف را فراهم می‌سازد.

۳-۶- ابزارهای کمکی برای پایش آموزش و مصورسازی

۳-۶-۱- توقف زودهنگام^۱ به عنوان راهکار کنترل بیش‌برازش

در این پروژه، به منظور کنترل پدیده‌ی بیش‌برازش^۲ و افزایش پایداری فرآیند آموزش، یک سازوکار توقف زودهنگام به صورت سفارشی پیاده‌سازی شده است. هدف از به‌کارگیری این روش، جلوگیری از ادامه‌ی آموزش در شرایطی است که بهبود معناداری در عملکرد مدل بر روی داده‌های اعتبارسنجی مشاهده نمی‌شود. برخلاف مقاله ConvNeXt V2 که فرآیند آموزش را بر روی مجموعه داده‌ی بسیار بزرگ ImageNet-1K انجام داده و از دوره‌های آموزشی طولانی مدت (تا epoch ۸۰۰ در فاز یادگیری خودنظارتی) بهره می‌برد، مجموعه داده‌ی سلول‌های خونی مورد استفاده در این پروژه از نظر حجم داده محدود و ماهیت پزشکی محور است [۹]. در چنین شرایطی، ادامه‌ی آموزش پس از رسیدن به کمینه‌ی خطای اعتبارسنجی می‌تواند منجر به یادگیری نویزهای خاص داده، کاهش تنوع بازنمایی‌ها و در نهایت افت قابلیت تعمیم مدل در داده‌های نادیده شود. به همین دلیل، استفاده از توقف زودهنگام به عنوان یک راهکار کنترلی، نقش مؤثری در حفظ تعادل میان یادگیری مؤثر و جلوگیری از بیش‌برازش در این پروژه ایفا می‌کند (شکل ۳-۶).

^۱ Early Stopping

^۲ Overfitting

```
# =====
# 2. UTILS: Visualization & Helpers
# =====
class EarlyStopping:
    def __init__(self, patience=5, min_delta=0):
        self.patience = patience
        self.min_delta = min_delta
        self.counter = 0
        self.best_loss = None
        self.early_stop = False
        self.best_model_state = None

    def __call__(self, val_loss, model):
        if self.best_loss is None:
            self.best_loss = val_loss
            self.best_model_state = copy.deepcopy(model.state_dict())
        elif val_loss > self.best_loss - self.min_delta:
            self.counter += 1
            if self.counter >= self.patience:
                self.early_stop = True
        else:
            self.best_loss = val_loss
            self.best_model_state = copy.deepcopy(model.state_dict())
            self.counter = 0

    def restore_best_weights(self, model):
        model.load_state_dict(self.best_model_state)
        print("    Restored best model weights.")

def denormalize(tensor):
    """Reverses the ImageNet normalization for visualization."""
    mean = torch.tensor([0.485, 0.456, 0.406]).view(3, 1, 1).to(tensor.device)
    std = torch.tensor([0.229, 0.224, 0.225]).view(3, 1, 1).to(tensor.device)
    return tensor * std + mean
```

شکل ۳-۶ پیاده‌سازی ابزارهای کمکی

کلاس توقف زودهنگام با تعریف دو ابرپارامتر کلیدی، یعنی `patience` و `min_delta`، فرآیند کنترل بیش‌برازش را مدیریت می‌کند. پارامتر `patience` مشخص می‌کند که مدل تا چند دوره‌ی آموزشی^۱ متوالی بدون مشاهده‌ی بهبود معنادار در خطای اعتبارسنجی مجاز به ادامه‌ی آموزش است، در حالی که `min_delta` حداقل میزان بهبود لازم برای در نظر گرفتن یک کاهش واقعی در مقدار خطا را تعیین می‌کند. این طراحی موجب می‌شود نوسانات کوچک و تصادفی در مقدار تابع هزینه منجر به توقف زودهنگام فرآیند آموزش نشوند.

در طول فرآیند آموزش، پس از پایان هر `epoch`، مقدار خطای اعتبارسنجی^۲ به شیء توقف زودهنگام ارسال می‌شود. در صورتی که این مقدار نسبت به بهترین مقدار ثبت‌شده بهبودی نداشته باشد، شمارنده‌ی داخلی افزایش می‌یابد و با عبور از آستانه‌ی تعیین‌شده توسط `patience`، فرآیند آموزش به‌صورت خودکار متوقف می‌شود. یکی از نکات مهم و حرفه‌ای در این پیاده‌سازی، ذخیره‌ی بهترین وزن‌های مدل با استفاده از دستور

^۱ epoch

^۲ val_loss

copy.deepcopy(model.state_dict()) است. در پایان آموزش، متد restore_best_weights تضمین می‌کند که مدل نهایی دقیقاً به حالتی بازگردانده شود که کمترین خطای اعتبارسنجی را داشته است، نه صرفاً به وضعیت مربوط به آخرین epoch آموزش.

از منظر تطبیق با مقاله‌ی مرجع، لازم به ذکر است که سازوکار توقف زودهنگام در پیاده‌سازی مقاله ConvNeXt V2 مورد استفاده قرار نگرفته است. با این حال، حذف این راهکار در پروژه‌ی حاضر منطقی نخواهد بود، زیرا مقاله‌ی مذکور بر مجموعه‌داده‌های بسیار بزرگ و تنظیمات نزدیک به سناریوهای صنعتی تمرکز دارد، در حالی که پروژه‌ی حاضر یک کاربرد پزشکی با حجم داده‌ی محدود را هدف قرار داده است. از این رو، به‌کارگیری توقف زودهنگام یک تصمیم مهندسی آگاهانه، قابل دفاع و متناسب با ماهیت داده‌ها و اهداف پژوهش محسوب می‌شود [۹].

۳-۶-۲- بازنرمال‌سازی تصاویر برای مصورسازی نتایج^۱

در بخش دوم این مرحله، تابعی با نام denormalize تعریف شده است که وظیفه‌ی آن بازگرداندن تصاویر نرمال‌سازی‌شده به مقیاس اصلی به‌منظور اهداف مصورسازی است. در مراحل پیش‌پردازش، تصاویر ورودی با استفاده از مقادیر میانگین و انحراف معیار ImageNet نرمال‌سازی می‌شوند. این اقدام به‌منظور هم‌راستاسازی توزیع داده‌ها با وزن‌های اولیه‌ی معماری ConvNeXt و افزایش پایداری فرآیند آموزش انجام می‌گیرد. با این حال، نمایش مستقیم تصاویر نرمال‌سازی‌شده از نظر بصری قابل تفسیر نبوده و تحلیل کیفی آن‌ها دشوار است. تابع denormalize با استفاده از همان مقادیر میانگین و انحراف معیار ImageNet، عملیات نرمال‌سازی را به‌صورت معکوس اعمال می‌کند و تصاویر را به بازه‌ی بصری قابل‌درک بازمی‌گرداند. این موضوع به‌ویژه در مرحله‌ی یادگیری خودنظارتی مبتنی بر چارچوب خودرمزگذار ماسک‌شده‌ی تمام‌کانولوشنی (FCMAE) اهمیت ویژه‌ای دارد، زیرا در این مرحله کیفیت بازسازی نواحی ماسک‌شده یکی از شواهد کیفی مهم برای ارزیابی توانایی مدل در یادگیری بازنمایی‌های معنادار محسوب می‌شود.

با استفاده از این تابع، امکان مقایسه‌ی بصری تصاویر ورودی، تصاویر ماسک‌شده و خروجی بازسازی‌شده‌ی رمزگشا فراهم می‌شود و می‌توان بررسی کرد که آیا مدل قادر است ساختارهای مورفولوژیکی سلول‌ها، نظیر هسته و سیتوپلاسم، را به‌درستی و به‌صورت معنادار بازسازی کند یا خیر.

¹ Denormalization

۳-۷-۷- معماری مدل پیشنهادی مبتنی بر ConvNeXt V2 و FCMAE

۳-۷-۱- نرمال سازی لایه‌ای سفارشی^۱

در این پروژه، یک پیاده‌سازی سفارشی از نرمال‌سازی لایه‌ای^۲ ارائه شده است که از هر دو قالب داده‌ای `channels_first` و `channels_last` پشتیبانی می‌کند. این طراحی به‌طور کامل با فلسفه‌ی معماری ConvNeXt هم‌راستا است؛ زیرا در بلوک‌های ConvNeXt، عملیات کانولوشن در قالب `channels_first` انجام می‌شود، در حالی که بخش شبه MLP، که معمولاً به‌صورت کانولوشن نقطه‌ای یا لایه‌های خطی پیاده‌سازی می‌شود، نیازمند تبدیل داده‌ها به قالب `channels_last` است.

پیاده‌سازی دستی نرمال‌سازی لایه‌ای این امکان را فراهم می‌کند که کنترل کاملی بر نحوه‌ی جابه‌جایی میان این دو قالب داده‌ای وجود داشته باشد و فرآیند نرمال‌سازی به‌صورت دقیق و سازگار با جریان داده‌ی کانولوشنی-MLP انجام گیرد. علاوه بر این، این رویکرد از وابستگی به پیاده‌سازی‌های پیش‌فرض و محدود کتابخانه PyTorch جلوگیری کرده و انعطاف‌پذیری بیشتری در طراحی معماری مدل فراهم می‌سازد.

در مقاله‌ی ConvNeXt V2، از نرمال‌سازی لایه‌ای به‌عنوان یکی از مؤلفه‌های معماری استفاده شده است، اما جزئیات مربوط به نحوه‌ی پیاده‌سازی آن به‌صورت انتزاعی بیان شده و وارد سطح کدنویسی نمی‌شود [۹]. در پروژه‌ی حاضر، به‌منظور انطباق کامل با جریان داده‌ی کانولوشنی-MLP و مدیریت صحیح جابه‌جایی میان قالب‌های `channels_first` و `channels_last`، نرمال‌سازی لایه‌ای به‌صورت صریح و سفارشی پیاده‌سازی شده است. این تفاوت صرفاً یک تصمیم مهندسی در سطح پیاده‌سازی محسوب می‌شود و هیچ‌گونه تفاوت مفهومی یا نظری با چارچوب ارائه‌شده در مقاله اصلی ایجاد نمی‌کند [۹].

۳-۷-۲- نرمال سازی پاسخ سراسری (GRN)

ماژول نرمال‌سازی پاسخ سراسری پیاده‌سازی شده در این پروژه مستقیماً از فرمول‌بندی ارائه‌شده در مقاله ConvNeXt V2 الهام گرفته شده است [۹]. در این لایه، ابتدا نِرم L_2 پاسخ هر کانال بر روی ابعاد مکانی محاسبه می‌شود و سپس این مقادیر با استفاده از میانگین پاسخ کانال‌ها نرمال‌سازی می‌گردند تا یک معیار از اهمیت نسبی هر کانال به دست آید. در ادامه، خروجی GRN با بهره‌گیری از دو پارامتر قابل یادگیری γ و β کالیبره شده و در نهایت از طریق یک اتصال باقی‌مانده^۳ به ورودی لایه افزوده می‌شود. این طراحی به‌طور مستقیم با هدف اصلی

¹ Layer Norm

² Layer Normalization


³ Residual Connection

مقاله، یعنی جلوگیری از پدیده‌ی فروپاشی ویژگی در آموزش خودنظارتی، هم‌راستا است. GRN با ایجاد رقابت سراسری میان کانال‌ها، تنوع بازنمایی‌ها را در لایه‌های عمیق شبکه حفظ می‌کند؛ مشکلی که در معماری ConvNeXt V1 تحت چارچوب FCMAE به‌صورت آشکار مشاهده شده بود [۹].

در مقاله ConvNeXt V2 اشاره شده است که در برخی پیاده‌سازی‌ها، فرآیند نرمال‌سازی ممکن است با فاکتور تعداد کانال‌ها C نیز مقیاس شود. با این حال، در پیاده‌سازی حاضر و با توجه به ماهیت پزشکی و حجم محدود مجموعه داده، از نسخه‌ی ساده‌تر GRN استفاده شده است تا پایداری عددی بهبود یابد و از بروز نوسانات ناخواسته در فرآیند آموزش جلوگیری شود. این تفاوت صرفاً یک تصمیم مهندسی در سطح پیاده‌سازی محسوب می‌شود و اثر مفهومی GRN یا نقش آن در جلوگیری از فروپاشی ویژگی را تغییر نمی‌دهد، بلکه آن را برای سناریوهای داده‌ی کم‌حجم مناسب‌تر می‌سازد [۹].

۳-۷-۳- بلوک ConvNeXt V2

کلاس Block در این پروژه پیاده‌سازی دقیقی از بلوک ConvNeXt V2 بوده و به‌طور کامل مطابق با طراحی ارائه‌شده در شکل ۷-۳ انجام شده است. هر بلوک شامل یک کانولوشن عمقی با کرنل 7×7 ، نرمال‌سازی لایه‌ای، یک ماژول شبه MLP کانال‌محور با افزایش بُعد ویژگی‌ها به $4 \times d$ و کاهش مجدد آن، تابع فعال‌سازی GELU و در نهایت لایه نرمال‌سازی پاسخ سراسری (GRN) می‌باشد. حذف مؤلفه LayerScale و جایگزینی آن با GRN دقیقاً مطابق با طراحی ConvNeXt V2 صورت گرفته است و اتصال باقی‌مانده نیز به‌منظور تضمین پایداری گرادیان و تسهیل فرآیند آموزش در بلوک لحاظ شده است.



شکل ۷-۳ طراحی بلوک‌های ConvNeXt. در ConvNeXt V2 [۱۳].

در این پیاده‌سازی، محل قرارگیری GRN پس از بخش MLP و تابع فعال‌سازی GELU انتخاب شده، LayerScale به‌طور کامل حذف گردیده و از کانولوشن عمقی^۱ به‌همراه MLP کانال‌محور استفاده شده است. از این رو، می‌توان گفت این بخش از نظر معماری و ترتیب مؤلفه‌ها، به‌صورت کامل با چارچوب ارائه‌شده در مقاله ConvNeXt V2 منطبق بوده و هیچ‌گونه انحراف مفهومی یا ساختاری نسبت به طراحی مرجع ندارد [۹].

۳-۷-۴- معماری ConvNeXt V2 Nano (رمزگذار)

مدل ConvNeXt V2 Nano به‌عنوان یکی از نسخه‌های سبک خانواده ConvNeXt V2، شامل چهار مرحله‌ی سلسله‌مراتبی با ابعاد کانالی [۴۰, ۸۰, ۱۶۰, ۳۲۰] و عمق [۲, ۲, ۶, ۲] است. این ساختار سلسله‌مراتبی امکان استخراج بازنمایی‌های چندمقیاسی را فراهم می‌کند و به‌ویژه برای داده‌هایی با جزئیات محلی ظریف و تغییرات مورفولوژیکی محدود، نظیر تصاویر سلول‌های خونی، بسیار مناسب است. ترکیب کانولوشن‌های عمقی، بلوک‌های ConvNeXt V2 و کاهش تدریجی وضوح فضایی، موجب می‌شود مدل بتواند هم‌زمان الگوهای محلی دقیق و ساختارهای معنایی سطح بالاتر را فرا بگیرد.

در مقاله‌ی مرجع ConvNeXt V2، اغلب از نسخه‌های بزرگ‌تر نظیر ConvNeXt Base یا Large و آموزش بر روی مجموعه‌داده‌ی ImageNet-1K استفاده شده است [۹]. در پروژه‌ی حاضر، انتخاب نسخه‌ی Nano یک تصمیم مهندسی آگاهانه محسوب می‌شود که با توجه به حجم محدود مجموعه‌داده‌ی پزشکی، محدودیت منابع محاسباتی و لزوم کاهش ریسک بیش‌برازش اتخاذ شده است. این تطبیق آگاهانه‌ی معماری با سناریوی داده‌های پزشکی کم‌حجم را می‌توان به‌عنوان یک سازگارسازی با رژیم داده‌ی پزشکی کم‌نمونه^۲ در گزارش نهایی پروژه مورد تأکید قرار داد.

۳-۷-۵- چارچوب خودرمزگذار ماسک‌شده‌ی تمام‌کانولوشنی (FCMAE)

کلاس FCMAE چارچوب کلی آموزش خودنظارتی مبتنی بر مدل‌سازی تصویر ماسک‌شده را در این پروژه پیاده‌سازی می‌کند. در این مدل، تصویر ورودی با نسبت ماسک ۰/۶ به‌صورت تصادفی ماسک شده و سپس به رمزگذار مبتنی بر معماری ConvNeXt V2 منتقل می‌شود. رمزگشای مدل از یک ساختار کانولوشنی سبک و نامتقارن بهره می‌برد که با بازیابی تدریجی وضوح فضایی، وظیفه‌ی بازسازی تصویر نهایی را بر عهده دارد. این عدم تقارن میان رمزگذار و رمزگشا به‌صورت آگاهانه طراحی شده است تا تمرکز اصلی فرآیند یادگیری بر استخراج بازنمایی‌های غنی و تعمیم‌پذیر در رمزگذار قرار گیرد.

^۱ Depthwise Convolution

^۲ Adaptation to Medical Small-Data Regime

در مقاله‌ی ConvNeXt V2، فرآیند ماسک‌گذاری در سطح پچ‌های 32×32 انجام شده و برای جلوگیری از نشت اطلاعات، از کانولوشن‌های تنک استفاده شده است [۹]. در مقابل، در پیاده‌سازی حاضر، ماسک‌گذاری به‌صورت پیکسل‌محور^۱ انجام شده و به‌جای پیاده‌سازی صریح کانولوشن‌های تنک، از اعمال مستقیم ماسک باینری بر ورودی و خروجی لایه‌های کانولوشنی استفاده شده است. این انتخاب یک تصمیم مهندسی آگاهانه محسوب می‌شود، زیرا پیاده‌سازی کانولوشن پراکنده^۲ از نظر فنی پیچیده‌تر بوده و در بسیاری از GPUهای عمومی از نظر کارایی بهینه نیست.

علاوه بر این، در خود مقاله ConvNeXt V2 نیز اشاره شده است که اعمال ماسک قبل و بعد از کانولوشن‌های متراکم، از منظر عددی معادل استفاده از کانولوشن‌های تنک زیرمانیفولد است. بر این اساس، رویکرد اتخاذ‌شده در این پروژه را می‌توان به‌عنوان یک تقریب ساده‌شده اما معتبر^۳ از چارچوب FCMAE در نظر گرفت که ضمن حفظ منطق مفهومی مقاله، امکان پیاده‌سازی پایدار و کارآمد را در یک سناریوی پزشکی با داده‌های محدود فراهم می‌سازد [۹].

۳-۷-۶- مدل تنظیم نهایی برای دسته‌بندی

در مرحله‌ی تنظیم نهایی، رمزگذار پیش‌آموزش‌دیده در چارچوب خودرمزگذار ماسک‌شده‌ی تمام کانولوشنی (FCMAE) به‌عنوان استخراج‌کننده‌ی ویژگی مورد استفاده قرار می‌گیرد و یک سر دسته‌بندی به آن افزوده می‌شود. این سر دسته‌بندی شامل نرمال‌سازی لایه‌ای، تجمیع میانگین سراسری^۴، یک لایه Dropout و در نهایت یک لایه کاملاً متصل^۵ برای انجام طبقه‌بندی نهایی است. افزودن Dropout با نرخ 0.5 یکی از تفاوت‌های مهم این پیاده‌سازی با مقاله‌ی مرجع محسوب می‌شود که به‌طور خاص با هدف کاهش بیش‌برازش در مجموعه داده‌ی پزشکی کوچک اعمال شده است [۹].

در مقاله‌ی ConvNeXt V2، به دلیل استفاده از مجموعه داده‌های بسیار بزرگ، راهبردهای منظم‌سازی به‌صورت حداقلی به‌کار گرفته شده‌اند [۹]. در مقابل، در پروژه‌ی حاضر، ماهیت پزشکی و حجم محدود داده‌ها ایجاب می‌کند که از تکنیک‌های منظم‌سازی صریح‌تری نظیر Dropout استفاده شود. این انتخاب یک تصمیم مهندسی آگاهانه و متناسب با شرایط مسئله محسوب می‌شود و با هدف افزایش قابلیت تعمیم مدل در داده‌های نادیده انجام شده است.

¹ Pixel-wise

² Sparse Convolution

³ Simplified but Valid Approximation

⁴ Global Average Pooling

⁵ Fully Connected

در مجموع، این بخش پیاده‌سازی کامل و عملی معماری ConvNeXt V2 به‌همراه چارچوب یادگیری خودنظارتی FCMAE را نشان می‌دهد. مؤلفه‌های کلیدی مقاله، از جمله لایه نرمال‌سازی پاسخ سراسری (GRN)، بلوک‌های ConvNeXt V2 و چارچوب FCMAE، با وفاداری بالا پیاده‌سازی شده‌اند. تفاوت‌های موجود، نظیر استفاده از نسخه Nano به‌جای مدل‌های بزرگ‌تر، به‌کارگیری ماسک‌گذاری پیکسل‌محور به‌جای پیچ‌محور، عدم پیاده‌سازی صریح کانولوشن‌های تنک، و افزودن راهبردهایی مانند Dropout و توقف زودهنگام، همگی تصمیمات مهندسی آگاهانه‌ای هستند که با ماهیت مجموعه‌داده‌ی پزشکی کوچک و محدودیت‌های محاسباتی پروژه هم‌راستا می‌باشند. این تطبیق‌ها نه تنها به‌عنوان ضعف تلقی نمی‌شوند، بلکه نشان‌دهنده‌ی درک عمیق از مقاله‌ی مرجع و توانایی تطبیق آن با یک مسئله‌ی واقعی و کاربردی هستند [۹].

۳-۸- پیش‌پردازش و تقسیم داده

۳-۸-۱- پیش‌پردازش تصاویر و تعریف تبدیل‌ها^۱

در این مرحله، عملیات پیش‌پردازش تصاویر ورودی به‌منظور آماده‌سازی آن‌ها برای ورود به معماری ConvNeXt V2 تعریف شده است. ابتدا تمامی تصاویر موجود در مجموعه‌داده به ابعاد ثابت 128×128 تغییر مقیاس داده می‌شوند تا ورودی یکنواخت و سازگاری برای مدل فراهم گردد. در ادامه، تصاویر به قالب Tensor تبدیل شده و با استفاده از مقادیر میانگین و انحراف معیار ImageNet نرمال‌سازی می‌شوند. این نرمال‌سازی موجب هم‌ترازی توزیع داده‌های ورودی با توزیع داده‌هایی می‌شود که مدل ConvNeXt در مرحله‌ی پیش‌آموزش اولیه بر روی آن‌ها آموزش دیده است و در نتیجه به پایداری و همگرایی بهتر فرآیند آموزش کمک می‌کند. انتخاب اندازه‌ی ورودی 128×128 به‌جای اندازه‌ی متداول 224×224 یک تصمیم مهندسی آگاهانه محسوب می‌شود که با هدف کاهش هزینه‌ی محاسباتی، افزایش سرعت آموزش و کاهش ریسک بیش‌برازش در مجموعه‌داده‌ی پزشکی با حجم محدود اتخاذ شده است. این انتخاب، ضمن حفظ اطلاعات مورفولوژیکی ضروری سلول‌های خونی، تعادل مناسبی میان صحت مدل و کارایی محاسباتی ایجاد می‌کند.

۳-۸-۲- بارگذاری مجموعه‌داده و استخراج تعداد کلاس‌ها

پس از تعریف تبدیل‌های پیش‌پردازش، کل مجموعه‌داده با استفاده از کلاس ImageFolder بارگذاری می‌شود. این کلاس، ساختار پوشه‌ای مجموعه‌داده را به‌عنوان منبع برچسب‌ها در نظر گرفته و به‌صورت خودکار تصاویر مربوط به هر کلاس را شناسایی و سازمان‌دهی می‌کند. استفاده از این رویکرد موجب می‌شود پیاده‌سازی مستقل

¹ Transforms

از نام یا تعداد کلاس‌ها بوده و در صورت تغییر در ساختار پوشه‌ها یا افزودن کلاس‌های جدید، نیازی به اعمال اصلاحات دستی در کد وجود نداشته باشد.

علاوه بر این، تعداد کلاس‌ها به صورت پویا و بر اساس ساختار مجموعه داده محاسبه می‌شود تا در مراحل بعدی، از جمله تعریف سر دسته‌بندی^۱ و محاسبه تابع هزینه، مورد استفاده قرار گیرد. این طراحی به افزایش انعطاف پذیری کد و کاهش خطاهای احتمالی در فرآیند پیاده‌سازی کمک می‌کند.

۳-۸-۳- استراتژی تقسیم داده

در این مرحله، کل مجموعه داده به چهار زیرمجموعه‌ی مستقل تقسیم می‌شود که هر یک نقش مشخصی در فرآیند سه مرحله‌ای پروژه ایفا می‌کنند. پنجاه درصد از داده‌ها به مرحله‌ی یادگیری خودنظارتی اختصاص داده شده‌اند تا مدل FCMAE بتواند بدون استفاده از برچسب‌ها، بازنمایی‌های غنی و تعمیم‌پذیری از تصاویر پزشکی استخراج کند. بیست و پنج درصد از داده‌ها برای آموزش نظارت شده در مرحله‌ی تنظیم نهایی، ده درصد برای اعتبارسنجی و تنظیم ابرپارامترها، و پانزده درصد باقی‌مانده برای آزمون نهایی^۲ در نظر گرفته شده است.

این تقسیم‌بندی با استفاده از تابع `random_split` و با تعیین یک `Seed` ثابت (۴۲) انجام شده است تا بازتولیدپذیری کامل نتایج تضمین شود. تفکیک صریح داده‌های مربوط به یادگیری خودنظارتی، آموزش نظارت شده، اعتبارسنجی و آزمون نهایی، یک تصمیم مهندسی مهم در این پروژه محسوب می‌شود که با هدف جلوگیری از نشت داده^۳ و ارائه‌ی ارزیابی واقع‌بینانه از عملکرد مدل در سناریوهای پزشکی اتخاذ شده است؛ موضوعی که در بسیاری از پیاده‌سازی‌های ساده‌شده نادیده گرفته می‌شود.

۳-۸-۴- تعریف DataLoaderها و تنظیمات بارگذاری داده‌ها

برای هر یک از زیرمجموعه‌های داده، یک `DataLoader` مجزا تعریف شده است تا فرآیند بارگذاری داده‌ها به صورت کنترل شده و متناسب با نقش هر زیرمجموعه انجام گیرد. در مراحل یادگیری، شامل فاز یادگیری خودنظارتی و مرحله‌ی تنظیم نهایی، داده‌ها به صورت تصادفی^۴ بارگذاری می‌شوند. این کار از بروز سوگیری ناشی از ترتیب داده‌ها جلوگیری کرده و به بهبود همگرایی مدل در طول آموزش کمک می‌کند.

^۱ Classification Head

^۲ Test

^۳ Data Leakage

^۴ Shuffle=True

در مقابل، در مراحل اعتبارسنجی و آزمون نهایی، گزینه‌ی Shuffle غیرفعال در نظر گرفته شده است تا نتایج ارزیابی پایدار، قابل تکرار و مستقل از ترتیب نمونه‌ها باشند. اندازه‌ی دسته‌ی آموزشی^۱ برابر ۶۴ انتخاب شده است که تعادل مناسبی میان مصرف حافظه، پایداری گرادیان‌ها و سرعت آموزش برقرار می‌کند. همچنین، مقدار num_workers=2 به منظور بهبود سرعت بارگذاری داده‌ها در محیط‌های محاسباتی متداول در نظر گرفته شده است، بدون آن که سربار اضافی قابل توجهی به سیستم تحمیل شود.

۳-۸-۵- گزارش آماری تقسیم داده‌ها

در انتهای این مرحله، تعداد نمونه‌های موجود در هر یک از زیرمجموعه‌های داده چاپ می‌شود. این خروجی، علاوه بر مستندسازی دقیق فرآیند تقسیم داده‌ها، به عنوان یک بررسی صحت اجرایی (Sanity Check) عمل می‌کند تا اطمینان حاصل شود که تقسیم‌بندی انجام شده با طراحی اولیه‌ی پروژه و نسبت‌های از پیش تعیین شده مطابقت دارد.

انجام این مرحله نقش مهمی در تضمین صحت آزمایش‌ها، جلوگیری از بروز خطاهای ناخواسته در مراحل بعدی آموزش و ارزیابی، و فراهم‌سازی بستر مناسب برای تفسیر صحیح و قابل اعتماد نتایج نهایی ایفا می‌کند (شکل ۳-۸).

```
# =====
# 4. EXECUTION & VISUALIZATION
# =====

img_size = 128
transform = transforms.Compose([
    transforms.Resize((img_size, img_size)),
    transforms.ToTensor(),
    transforms.Normalize(mean=[0.485, 0.456, 0.406], std=[0.229, 0.224, 0.225])
])
full_dataset = datasets.ImageFolder(root=data_root, transform=transform)
num_classes = len(CLASSES_NAMES)

# Split
total_size = len(full_dataset)
ssl_size = int(0.50 * total_size)
ft_train_size = int(0.25 * total_size)
ft_val_size = int(0.10 * total_size)
test_size = total_size - ssl_size - ft_train_size - ft_val_size

ds_ssl, ds_ft_train, ds_ft_val, ds_test = random_split(
    full_dataset, [ssl_size, ft_train_size, ft_val_size, test_size],
    generator=torch.Generator().manual_seed(42)
)

dl_ssl = DataLoader(ds_ssl, batch_size=64, shuffle=True, num_workers=2)
dl_ft_train = DataLoader(ds_ft_train, batch_size=64, shuffle=True, num_workers=2)
dl_ft_val = DataLoader(ds_ft_val, batch_size=64, shuffle=False, num_workers=2)
dl_test = DataLoader(ds_test, batch_size=64, shuffle=False, num_workers=2)

print(f" Dataset: SSL={len(ds_ssl)}, Train={len(ds_ft_train)}, Val={len(ds_ft_val)}, Test={len(ds_test)}")
```

شکل ۳-۸ پیاده‌سازی پیش‌پردازش و تقسیم داده

¹ Batch Size

۳-۹- فاز اول: پیش آموزش خودنظارتی

در این بخش، فاز نخست فرآیند یادگیری، یعنی پیش آموزش خودنظارتی مبتنی بر چارچوب خودرمزگذار ماسک شده‌ی تمام کانولوشنی (FCMAE) اجرا می‌شود. در این مرحله، یک رمزگذار از نوع ConvNeXt V2 Nano به عنوان هسته‌ی اصلی استخراج ویژگی انتخاب شده و درون معماری FCMAE قرار می‌گیرد. انتخاب نسخه‌ی Nano یک تصمیم مهندسی آگاهانه محسوب می‌شود که با در نظر گرفتن ماهیت مجموعه داده‌ی پزشکی مورد استفاده، از جمله حجم محدود داده‌ها و ریسک بالای بیش‌برازش، و همچنین محدودیت منابع محاسباتی اتخاذ شده است. با وجود این ساده سازی، ساختار مدرن ConvNeXt V2 و لایه‌ی نرمال سازی پاسخ سراسری (GRN) به طور کامل حفظ شده‌اند تا مدل همچنان قادر به یادگیری بازنمایی‌های غنی و تعمیم‌پذیر در مرحله‌ی پیش آموزش خودنظارتی باشد.

۳-۹-۱- تنظیمات بهینه سازی و تابع هزینه

به منظور بهینه سازی پارامترهای مدل در فاز پیش آموزش خودنظارتی، از الگوریتم AdamW با نرخ یادگیری 10^{-3} و ضریب منظم سازی وزن‌ها^۱ برابر با ۰/۰۵ استفاده شده است. این انتخاب با رویه‌های رایج در پیش آموزش مدل‌های بینایی مدرن هم‌خوانی داشته و به کنترل رشد وزن‌ها، کاهش بیش‌برازش و افزایش پایداری فرآیند آموزش کمک می‌کند.

تابع هزینه‌ی مورد استفاده در این مرحله از نوع میانگین مربعات خطا (MSE) است که اختلاف میان تصویر بازسازی شده توسط رمزگشا و تصویر هدف را اندازه گیری می‌کند. مشابه آنچه در مقاله ConvNeXt V2 گزارش شده است، بازسازی تصویر به عنوان سیگنال یادگیری اصلی در چارچوب FCMAE عمل می‌کند و مدل را وادار می‌سازد تا بازنمایی‌های غنی، معنادار و وابسته به زمینه‌ی تصویری را در رمزگذار فرا بگیرد [۹].

۳-۹-۲- استراتژی ماسک گذاری و روند آموزش در فاز خودنظارتی

در هر تکرار آموزشی، تصاویر ورودی با نسبت ماسک گذاری بالا ($mask_{ratio} = 0.6$) به مدل ارائه می‌شوند؛ بدین معنا که ۶۰٪ از پیکسل‌های تصویر به صورت تصادفی حذف شده و مدل موظف است صرفاً بر اساس اطلاعات باقی مانده، تصویر کامل را بازسازی کند. این مقدار ماسک گذاری دقیقاً منطبق با تنظیمات پیشنهادی در مقاله ConvNeXt V2 انتخاب شده و تعادل مناسبی میان دشواری مسئله‌ی بازسازی و کیفیت سیگنال یادگیری فراهم می‌سازد [۹].

¹ Weight Decay

آموزش مدل در این فاز به مدت ۱۵ دوره‌ی آموزشی^۱ انجام شده است که با توجه به اندازه‌ی مجموعه داده‌ی پزشکی و هدف اصلی پروژه، یعنی یادگیری بازنمایی‌های مؤثر به جای همگرایی کامل بر روی مجموعه داده‌های بسیار بزرگ، یک انتخاب عملی و مبتنی بر ملاحظات مهندسی محسوب می‌شود. در طول فرآیند آموزش، مقدار تابع هزینه برای هر دسته‌ی داده به صورت بلادرنگ با استفاده از ابزار tqdm نمایش داده شده و میانگین مقدار خطا در انتهای هر epoch ذخیره می‌گردد تا امکان تحلیل روند همگرایی مدل در مراحل بعدی فراهم شود.

۳-۹-۳- ارزیابی کیفی: بازسازی تصاویر در داده‌های دیده نشده

پس از اتمام مرحله‌ی پیش‌آموزش خودنظارتی، مدل در حالت ارزیابی^۲ قرار داده می‌شود و کیفیت بازنمایی‌های آموخته شده از طریق بازسازی تصاویر دیده نشده^۳ مورد بررسی قرار می‌گیرد. در این مرحله، تعدادی تصویر از زیرمجموعه‌ی آزمون نهایی انتخاب شده و بدون به روزرسانی گرادیان‌ها، به مدل ارائه می‌شوند. این طراحی از منظر روش‌شناسی اهمیت بالایی دارد، زیرا تضمین می‌کند که ارزیابی بازسازی تصاویر به صورت کاملاً مستقل از داده‌های مورد استفاده در فاز یادگیری خودنظارتی انجام شده و از بروز نشت داده جلوگیری می‌شود. بررسی کیفی نتایج بازسازی در داده‌های نادیده، شواهد بصری مهمی از توان مدل در یادگیری ساختارهای مورفولوژیکی و وابستگی‌های مکانی موجود در تصاویر سلول‌های خونی فراهم می‌کند و به عنوان مکمل ارزیابی‌های کمی در مراحل بعدی مورد استفاده قرار می‌گیرد.

۳-۹-۴- بازنرمال سازی تصاویر و آماده سازی برای مصورسازی

از آنجا که تصاویر ورودی در مراحل پیش پردازش با استفاده از میانگین و انحراف معیار ImageNet نرمال سازی شده‌اند، پیش از انجام مصورسازی، عملیات بازنرمال سازی^۴ بر روی خروجی‌ها اعمال می‌شود تا مقادیر پیکسلی به بازه‌ای قابل تفسیر از نظر بصری بازگردانده شوند. انجام این مرحله برای قضاوت کیفی صحیح درباره‌ی نتایج بازسازی، به ویژه در داده‌های پزشکی، ضروری است.

علاوه بر تصویر بازسازی شده توسط مدل، تصویر ماسک شده‌ی ورودی نیز محاسبه و نمایش داده می‌شود تا امکان مقایسه‌ی مستقیم میان اطلاعات ناقص ورودی و خروجی بازسازی شده فراهم گردد. این مقایسه بصری نقش مهمی در ارزیابی کیفی توان مدل در بازسازی ساختارهای مورفولوژیکی سلول‌ها و درک وابستگی‌های مکانی موجود در تصاویر ایفا می‌کند.

¹ epoch

² Evaluation Mode

³ Unseen Test Data

⁴ Denormalization

۳-۹-۵- نمایش نتایج بازسازی (بررسی صحت بصری)

در نهایت، نتایج بازسازی مدل در قالب یک شکل سه‌ردیفه به نمایش گذاشته می‌شوند. ردیف نخست شامل تصاویر اصلی، ردیف دوم شامل تصاویر ورودی ماسک‌شده و ردیف سوم شامل تصاویر بازسازی‌شده توسط چارچوب FCMAE است. این مصورسازی نقش یک بررسی صحت بصری^۱ بسیار مهم را ایفا می‌کند و نشان می‌دهد که آیا مدل توانسته است از داده‌های ناقص، ساختارهای معنادار و الگوهای مورفولوژیکی سلول‌های خونی را به‌درستی فرا بگیرد یا خیر.

ذخیره‌ی این تصویر با وضوح بالا ($\text{dpi} = 300$) امکان استفاده‌ی مستقیم از آن را در گزارش نهایی، پایان‌نامه یا مقاله‌ی علمی فراهم می‌سازد [۹]. به‌طور خلاصه، این بخش فاز نخست پروژه را تکمیل می‌کند که شامل پیش‌آموزش خودنظارتی معماری ConvNeXt V2 در قالب FCMAE و ارزیابی کیفی بازنمایی‌های آموخته‌شده است. این فاز، بستر لازم برای انتقال دانش به مرحله‌ی تنظیم نهایی نظارت‌شده را فراهم کرده و نقش کلیدی در بهبود تعمیم‌پذیری مدل در وظیفه‌ی نهایی تشخیص سلول‌های سرطانی ایفا می‌نماید.

۳-۱۰- انتقال دانش از فاز اول به فاز دوم

در این مرحله، فاز دوم پروژه که شامل یادگیری نظارت‌شده است آغاز می‌شود. رمزگذار پیش‌آموزش‌دیده در فاز یادگیری خودنظارتی، یعنی معماری ConvNeXt V2 Nano آموزش‌دیده در چارچوب FCMAE، بدون مقداردهی مجدد وزن‌ها به‌عنوان هسته‌ی اصلی استخراج ویژگی مورد استفاده قرار می‌گیرد. این انتقال مستقیم وزن‌ها، هدف بنیادی یادگیری خودنظارتی، یعنی یادگیری بازنمایی‌های تعمیم‌پذیر و قابل انتقال به وظایف پایین‌دستی، را به‌طور عملی محقق می‌سازد.

بر روی این رمزگذار، یک سر دسته‌بندی^۲ با تعداد خروجی برابر با تعداد کلاس‌های مجموعه‌داده‌ی پزشکی افزوده می‌شود تا مدل بتواند در قالب یک چارچوب نظارت‌شده، فرآیند تمایز و طبقه‌بندی انواع سلول‌های خونی را فرا بگیرد. این مرحله نقطه‌ی اتصال میان یادگیری بازنمایی خودنظارتی و کاربرد عملی آن در وظیفه‌ی تشخیص سلول‌های سرطانی محسوب می‌شود.

¹ Visual Sanity Check

² Classification Head

۳-۱۰-۱- طراحی سر طبقه‌بندی و راهبردهای منظم‌سازی

در مرحله‌ی تنظیم نهایی، سر طبقه‌بندی مدل از یک لایه‌ی Dropout با نرخ نسبتاً بالا (۰/۵) بهره می‌برد. این انتخاب یک تصمیم مهندسی آگاهانه برای مقابله با بیش‌برازش در مجموعه داده‌های پزشکی با حجم محدود محسوب می‌شود؛ شرایطی که در آن مدل‌های عمیق مستعد یادگیری سریع الگوهای سطحی و خاص داده هستند. به‌کارگیری Dropout در سر طبقه‌بندی، برخلاف فاز یادگیری خودنظارتی، موجب افزایش پایداری فرآیند آموزش نظارت‌شده و بهبود قابلیت تعمیم مدل در داده‌های دیده‌نشده می‌شود. این راهبرد منظم‌سازی نقش مهمی در تضمین عملکرد قابل اعتماد مدل در کاربردهای واقعی تشخیص پزشکی ایفا می‌کند.

۳-۱۰-۲- تنظیمات بهینه‌سازی و تابع هزینه

به‌منظور بهینه‌سازی کل مدل در مرحله‌ی تنظیم نهایی، از الگوریتم AdamW با نرخ یادگیری 5×10^{-4} و ضریب منظم‌سازی وزن‌ها^۱ برابر با 10^{-4} استفاده شده است. کاهش نرخ یادگیری نسبت به فاز پیش‌آموزش خودنظارتی، یک تصمیم استاندارد و ضروری در سناریوهای انتقال یادگیری محسوب می‌شود، زیرا وزن‌های رمزگذار در مرحله‌ی پیشین، ساختارهای معناداری از داده‌ها آموخته‌اند و در این مرحله نیازمند به‌روزرسانی‌های ملایم‌تر و کنترل‌شده هستند.

تابع هزینه‌ی مورد استفاده در این فاز از نوع آنتروپی متقاطع^۲ است که به‌عنوان یک انتخاب مرسوم و مناسب برای مسائل طبقه‌بندی چندکلاسه شناخته می‌شود. استفاده از این تابع هزینه امکان یادگیری مؤثر مرزهای تصمیم میان کلاس‌های مختلف سلول‌های خونی را فراهم می‌سازد و با هدف نهایی پروژه، یعنی تشخیص دقیق سلول‌های سرطانی، هم‌راستا است.

۳-۱۰-۳- حلقه‌ی آموزش نظارت‌شده^۳

فرآیند تنظیم نهایی به‌گونه‌ای طراحی شده است که حداکثر به‌مدت ۵۰ دوره‌ی آموزشی اجرا شود. در ابتدای هر epoch، مدل در حالت آموزش^۴ قرار می‌گیرد و پارامترهای آن با استفاده از داده‌های مجموعه‌ی آموزش مربوط به مرحله‌ی تنظیم نهایی به‌روزرسانی می‌شوند. در طول این مرحله، مقدار تابع هزینه و صحت طبقه‌بندی به‌صورت تجمعی محاسبه و ثبت می‌گردد تا امکان ارزیابی روند یادگیری مدل فراهم شود.

^۱ Weight Decay

^۲ Cross-Entropy Loss

^۳ Training Loop

^۴ Training Mode

استفاده از ابزار tqdm برای نمایش نوار پیشرفت آموزش، علاوه بر افزایش شفافیت فرآیند اجرا، امکان پایش بلادرنگ رفتار مدل، تشخیص زودهنگام ناپایداری‌ها و ارزیابی سرعت همگرایی را فراهم می‌سازد.

۳-۱۰-۴- مرحله‌ی اعتبارسنجی و پایش تعمیم‌پذیری مدل

پس از پایان هر دوره‌ی آموزشی، مدل در حالت ارزیابی^۱ قرار می‌گیرد و عملکرد آن بر روی مجموعه‌ی اعتبارسنجی^۲ مورد سنجش قرار می‌گیرد. در این مرحله، محاسبه‌ی گرادیان‌ها غیرفعال می‌شود تا از هرگونه به‌روزرسانی ناخواسته‌ی پارامترها جلوگیری شده و فرآیند ارزیابی به‌صورت کاملاً مستقل از آموزش انجام گیرد. محاسبه‌ی مقدار تابع هزینه و صحت طبقه‌بندی بر روی داده‌های اعتبارسنجی، شاخص اصلی برای ارزیابی توان تعمیم‌پذیری مدل و تشخیص زودهنگام آغاز بیش‌برازش محسوب می‌شود. پایش منظم این معیارها امکان اعمال تصمیمات کنترلی، نظیر توقف زودهنگام یا تنظیم ابرپارامترها، را در مراحل بعدی آموزش فراهم می‌کند.

۳-۱۰-۵- ذخیره‌سازی و تحلیل تاریخچه‌ی آموزش

در طول فرآیند تنظیم نهایی، مقادیر تابع هزینه و صحت طبقه‌بندی برای هر دو مجموعه‌ی آموزش و اعتبارسنجی در یک ساختار تاریخچه به‌صورت منظم ذخیره می‌شوند. این اطلاعات امکان ترسیم منحنی‌های یادگیری^۳ و تحلیل رفتار همگرایی مدل را در مراحل بعدی فراهم می‌کنند. تحلیل این منحنی‌ها نقش مهمی در ارزیابی پایداری فرآیند آموزش، تشخیص بیش‌برازش یا کم‌برازش، و بررسی تأثیر راهبردهای منظم‌سازی مورد استفاده ایفا می‌کند. ارائه‌ی این نتایج در گزارش نهایی یا پایان‌نامه از منظر علمی ضروری است و نشان می‌دهد که آموزش مدل به‌صورت کنترل‌شده، قابل تکرار و مبتنی بر تحلیل دقیق انجام شده است.

۳-۱۰-۶- توقف زودهنگام

به‌منظور جلوگیری از بیش‌برازش و کاهش هزینه‌ی محاسباتی، از سازوکار توقف زودهنگام در فرآیند تنظیم نهایی استفاده شده است. این مکانیزم بر اساس مقدار تابع هزینه‌ی مجموعه‌ی اعتبارسنجی عمل می‌کند و در صورتی که طی ۵ دوره‌ی آموزشی متوالی، بهبود معناداری (بیش از حداقل مقدار تعیین‌شده) در مقدار Loss مشاهده نشود، فرآیند آموزش به‌صورت خودکار متوقف می‌گردد. استفاده از این راهبرد در مجموعه‌داده‌های پزشکی از

¹ Evaluation Mode

² Validation Set

³ Learning Curves

اهمیت ویژه‌ای برخوردار است، زیرا مدل‌های عمیق در چنین داده‌هایی معمولاً سریع‌تر از سناریوهای بزرگ مقیاس دچار بیش‌برازش می‌شوند.

پس از پایان فرآیند آموزش، چه در اثر رسیدن به حداکثر تعداد epochها و چه به دلیل فعال شدن توقف زودهنگام، بهترین وزن‌های ذخیره‌شده بر اساس عملکرد روی مجموعه‌ی اعتبارسنجی بازیابی می‌شوند. این رویکرد تضمین می‌کند که مدل نهایی مورد استفاده در فاز آزمون، بهترین نسخه‌ی ممکن از نظر تعمیم‌پذیری باشد. در مجموع، این مرحله نشان می‌دهد که چگونه بازنمایی‌های آموخته‌شده در فاز پیش‌آموزش خودنظارتی به صورت مؤثر به یک مسئله‌ی واقعی طبقه‌بندی پزشکی منتقل شده‌اند و نقش کلیدی یادگیری خودنظارتی در بهبود عملکرد نهایی مدل و افزایش قابلیت تعمیم آن به داده‌های دیده‌نشده را برجسته می‌سازد.

۳-۱۱- ارزیابی مدل و معیارهای عملکرد

پس از تکمیل فرآیند تنظیم نهایی، مقادیر ثبت‌شده‌ی تابع هزینه^۱ و صحت طبقه‌بندی برای مجموعه‌های آموزش و اعتبارسنجی در هر دوره‌ی آموزشی استخراج و ترسیم شدند تا روند همگرایی مدل به صورت دقیق مورد بررسی قرار گیرد. منحنی‌های هزینه آموزش و هزینه ارزیابی نشان می‌دهند که مدل با کاهش یکنواخت خطا در داده‌های آموزشی پیش می‌رود و هم‌زمان، روند کاهشی مشابهی در داده‌های اعتبارسنجی مشاهده می‌شود. نزدیکی این دو منحنی بیانگر تعادل مناسب میان یادگیری و تعمیم‌پذیری مدل بوده و نشان می‌دهد که مکانیزم توقف زودهنگام در تثبیت وزن‌های بهینه و جلوگیری از بیش‌برازش عملکرد مؤثری داشته است.

همچنین، منحنی‌های صحت آموزش و صحت اعتبارسنجی به صورت هم‌زمان ترسیم شده‌اند. افزایش تدریجی هر دو معیار در طول دوره‌های آموزشی و نوسانات کنترل‌شده در انتهای فرآیند آموزش نشان می‌دهد که مدل نه تنها توانسته است بازنمایی‌های معنادار آموخته‌شده در فاز پیش‌آموزش خودنظارتی را به مرحله‌ی طبقه‌بندی منتقل کند، بلکه در داده‌های اعتبارسنجی نیز ویژگی‌های تمایزگر مورفولوژیکی سلول‌های خونی را به درستی فرا گرفته است. این نتایج شواهد تجربی روشنی از کارایی یادگیری خودنظارتی در بهبود عملکرد طبقه‌بندی نهایی ارائه می‌دهند.

در ادامه، مدل طبقه‌بندی نهایی که از رمزگذار پیش‌آموزش‌دیده در فاز SSL بهره می‌برد، در حالت ارزیابی^۲ قرار داده شده و ارزیابی کامل آن بر روی مجموعه‌ی آزمون^۳ انجام شده است. این مرحله بدون محاسبه‌ی گرادیان‌ها و

^۱ Loss

^۲ eval

^۳ Test Set

صرفاً با استفاده از داده‌های کاملاً دیده‌نشده اجرا گردید تا معیارهای قابلیت تعمیم مدل، صحت کلی و حساسیت آن نسبت به کلاس‌های پزشکی مختلف به‌صورت واقع‌بینانه ارزیابی شوند.

برای تحلیل جامع عملکرد مدل در این مرحله، سه ابزار و معیار کلیدی مورد استفاده قرار گرفته‌اند:

(۱) گزارش آماری طبقه‌بندی^۱، به‌منظور بررسی صحت، یادآوری و امتیاز F1 برای هر کلاس؛

(۲) ماتریس سردرگمی^۲، جهت تحلیل الگوهای خطا و میزان تفکیک‌پذیری کلاس‌ها؛

(۳) منحنی‌های ROC چندکلاسه، برای ارزیابی توان تمایز مدل میان کلاس‌ها در سطوح مختلف آستانه تصمیم‌گیری.

مجموع این تحلیل‌ها تصویری جامع از عملکرد مدل ارائه می‌دهد و نقش مؤثر پیش‌آموزش خودنظارتی مبتنی بر FCMAE و معماری ConvNeXt V2 را در بهبود تعمیم‌پذیری و صحت تشخیص سلول‌های سرطانی برجسته می‌سازد.

۳-۱۱-۱- گزارش طبقه‌بندی (Precision، Recall و F1-Score)

در گام نخست ارزیابی کمی، خروجی‌های نهایی مدل پس از اعمال تابع Softmax و انتخاب کلاس با بیشینه‌ی احتمال، برای محاسبه‌ی معیارهای صحت، بازخوانی و امتیاز F1 برای هر یک از کلاس‌ها مورد استفاده قرار گرفتند. نتایج این ارزیابی در قالب یک گزارش متنی استاندارد ذخیره شده و در فایل classification_report.txt مستندسازی گردیده است.

اهمیت این مرحله در امکان تحلیل توازن میان حساسیت مدل در شناسایی نمونه‌های مثبت واقعی، که در حوزه‌ی تشخیص سلول‌های سرطانی و به‌ویژه کلاس‌های نادر اهمیت حیاتی دارد، و صحت مدل در کاهش پیش‌بینی‌های مثبت نادرست برای سلول‌های سالم نهفته است. دستیابی به مقادیر بالای F1-Score برای کلاس‌های غیرنرمال در خروجی نهایی نشان می‌دهد که بازنمایی‌های آموخته‌شده در فاز پیش‌آموزش خودنظارتی، به‌صورت مؤثری به مرحله‌ی تنظیم نهایی منتقل شده و در تصمیم‌گیری طبقه‌بندی به‌درستی مورد استفاده قرار گرفته‌اند.

۳-۱۱-۲- ماتریس سردرگمی

رگام بعدی ارزیابی، ماتریس سردرگمی به‌عنوان یک چارچوب تحلیلی تکمیلی برای بررسی جزئیات عملکرد مدل مورد استفاده قرار گرفت. در این ماتریس، تعداد پیش‌بینی‌های صحیح و نادرست برای هر یک از کلاس‌ها به‌صورت

¹ Classification Report

² Confusion Matrix

تفکیک شده نمایش داده می شود و امکان تحلیل دقیق الگوهای خطا و میزان تفکیک پذیری میان کلاس های مختلف را فراهم می سازد.

این نمایش به صورت تصویری و در قالب یک نقشه ی حرارتی^۱ ترسیم و در یک فایل مستقل ذخیره گردید. استفاده از نمایش حرارتی، با برجسته سازی نواحی با تراکم خطای بالا یا صحت بالا، به درک بصری سریع تر عملکرد مدل کمک کرده و مشخص می کند که کدام کلاس ها بیشترین میزان اشتباه یا هم پوشانی را در فرآیند طبقه بندی دارند؛ موضوعی که در تحلیل مدل های تشخیص پزشکی از اهمیت ویژه ای برخوردار است.

۳-۱۱-۳- منحنی ROC چند کلاسه و مساحت زیر منحنی (AUC)

به منظور ارزیابی جامع تر توان مدل در تمایز میان کلاس های مختلف، منحنی های مشخصه عملیاتی گیرنده^۲ (ROC) به صورت چند کلاسه و به طور جداگانه برای هر کلاس ترسیم شدند و مساحت زیر هر منحنی^۳ (AUC) محاسبه گردید. این تحلیل امکان بررسی عملکرد مدل را در سطوح مختلف آستانه ی تصمیم گیری فراهم می سازد و مستقل از انتخاب یک آستانه ی خاص، دید دقیق تری از قدرت تفکیک پذیری مدل ارائه می دهد.

منحنی های ROC و مقادیر AUC حاصل، در قالب یک شکل واحد ذخیره شده اند (فایل ۴_roc_curves.png). مقادیر بالای AUC برای کلاس های غیر نرمال نشان دهنده ی توان بالای مدل در تمایز نمونه های سرطانی از سلول های سالم است و مؤید آن است که بازنمایی های آموخته شده در فاز پیش آموزش خود نظارتی به صورت مؤثری به مرحله ی طبقه بندی منتقل شده اند. این معیار به ویژه در مسائل تشخیص پزشکی اهمیت دارد، زیرا حساسیت مدل نسبت به تغییر آستانه ی تصمیم گیری را به خوبی منعکس می کند و مکمل مناسبی برای معیارهایی نظیر Accuracy و F1-Score محسوب می شود.

۳-۱۱-۴- صحت نهایی مدل بر روی مجموعه ی آزمون

در انتهای فرآیند ارزیابی، صحت کلی مدل بر روی مجموعه ی آزمون محاسبه و به صورت درصد گزارش شد. این مقدار نهایی نشان دهنده ی عملکردی فراتر از مدل هایی است که از ابتدا و بدون پیش آموزش آموزش داده می شوند و به طور مستقیم اثرگذاری مرحله ی پیش آموزش خود نظارتی را تأیید می کند. نتایج نشان می دهند که مدل با اتکا به رمزگذار پیش آموزش دیده در چارچوب FCMAE، قادر بوده است سلول های خونی با سطوح مختلف سلامت و بیماری را با صحت بالا و پایداری مناسب طبقه بندی کند.

¹ Heatmap

² Receiver Operating Characteristic

³ Area Under the Curve

به‌طور کلی، نتایج فاز ارزیابی نشان می‌دهد که طراحی معماری ConvNeXt V2 Nano در چارچوب مدل‌سازی تصویر ماسک‌شده‌ی پیکسل‌محور، در کنار به‌کارگیری راهبردهای منظم‌سازی نظیر Dropout و توقف زودهنگام، منجر به مدلی با قابلیت تعمیم‌پذیری بالا و حساسیت مناسب برای تشخیص دقیق سلول‌های مرتبط با سرطان خون شده است.

تحلیل‌های بصری و عددی حاصل از منحنی‌های یادگیری، ماتریس درهم‌ریختگی، منحنی‌های ROC و گزارش آماری طبقه‌بندی به‌طور هم‌زمان نشان می‌دهند که مدل نه‌تنها به همگرایی پایدار دست یافته است، بلکه بازنمایی‌های آموخته‌شده در فاز پیش‌آموزش خودنظارتی به‌صورت مؤثر و معنادار در فرآیند تشخیص پزشکی نهایی مورد استفاده قرار گرفته‌اند. این نتایج نقش کلیدی یادگیری خودنظارتی را در بهبود عملکرد مدل‌های عمیق در سناریوهای پزشکی با داده‌ی محدود برجسته می‌سازد.

۳-۱۲- جمع‌بندی

در این فصل، روش انجام پژوهش و پیاده‌سازی عملی مدل پیشنهادی به‌صورت گام‌به‌گام و نظام‌مند تشریح شد. در ابتدا، محیط محاسباتی، مجموعه‌داده‌ی مورد استفاده و ملاحظات مهندسی داده معرفی گردید و نشان داده شد که چگونه انتخاب یک دیتاست پزشکی با حجم محدود، نیازمند تصمیمات آگاهانه در طراحی معماری، پیش‌پردازش داده‌ها و استراتژی آموزش است. سپس فرآیند پیش‌پردازش تصاویر، تقسیم داده‌ها به زیرمجموعه‌های مستقل و تنظیم DataLoaderها به‌گونه‌ای طراحی شد که از نشت داده جلوگیری شده و بازتولیدپذیری آزمایش‌ها تضمین گردد.

در ادامه، معماری ConvNeXt V2 و چارچوب (FCMAE) به‌عنوان هسته‌ی اصلی یادگیری خودنظارتی معرفی و پیاده‌سازی شد. در این راستا، مؤلفه‌های کلیدی مقاله مرجع، از جمله بلوک ConvNeXt V2، نرمال‌سازی پاسخ سراسری (GRN) و مدل‌سازی تصویر ماسک‌شده، با وفاداری بالا پیاده‌سازی شدند [۹]. در عین حال، برخی تغییرات مهندسی آگاهانه، نظیر استفاده از نسخه‌ی Nano، ماسک‌گذاری پیکسل‌محور، حذف پیاده‌سازی صریح Sparse Convolution، و به‌کارگیری Dropout و Early Stopping، با هدف تطبیق مدل با ماهیت داده‌های پزشکی کم‌حجم اعمال گردید. این تصمیمات نه‌تنها از اعتبار روش نمی‌کاهند، بلکه نشان‌دهنده‌ی درک عمیق چارچوب نظری و توان تطبیق آن با یک مسئله‌ی واقعی هستند.

فاز نخست آموزش به پیش‌آموزش خودنظارتی اختصاص یافت که در آن مدل بدون استفاده از برچسب‌ها، بازنمایی‌های معنادار و وابسته به ساختار مورفولوژیکی سلول‌های خونی را فرا گرفت. ارزیابی‌های کیفی بازسازی تصاویر دیده‌نشده نشان داد که مدل قادر به درک و بازسازی الگوهای مهم تصویری است. در فاز دوم، این بازنمایی‌ها

به مرحله‌ی یادگیری نظارت‌شده منتقل شدند و مدل با استفاده از یک سر طبقه‌بندی مناسب، برای وظیفه‌ی تشخیص سلول‌های خونی آموزش دید.

در نهایت، با استفاده از معیارهای کمی و بصری شامل منحنی‌های یادگیری، گزارش طبقه‌بندی، ماتریس سردرگمی، منحنی‌های ROC و صحت نهایی روی مجموعه‌ی آزمون، عملکرد مدل به‌طور جامع ارزیابی شد. نتایج به‌دست‌آمده نشان دادند که پیش‌آموزش خودنظارتی مبتنی بر FCMAE نقش مؤثری در بهبود تعمیم‌پذیری و صحت مدل در طبقه‌بندی پزشکی ایفا می‌کند. بدین ترتیب، فصل سوم چارچوب روش‌شناختی و پیاده‌سازی پژوهش را به‌طور کامل تثبیت کرده و زمینه‌ی لازم برای تحلیل و بحث نتایج در فصل بعدی را فراهم می‌سازد.

فصل چہارم: نتائج

۴-۱- مقدمه

در این فصل، نتایج حاصل از پیاده‌سازی و آموزش مدل پیشنهادی ارائه و به‌صورت جامع مورد تحلیل و تفسیر قرار می‌گیرند. با توجه به اینکه فصل سوم به تشریح کامل روش پژوهش، معماری مدل، مراحل پیش‌آموزش خودنظارتی و فرآیند تنظیم نهایی نظارت‌شده اختصاص داشت، تمرکز فصل حاضر بر ارزیابی تجربی عملکرد مدل و بررسی میزان موفقیت آن در تحقق اهداف پژوهش است.

در ابتدا، نتایج کمی حاصل از آموزش و ارزیابی مدل شامل منحنی‌های یادگیری، صحت نهایی، معیارهای Recall، Precision و F1-Score، ماتریس درهم‌ریختگی و منحنی‌های ROC چندکلاسه ارائه می‌شوند تا عملکرد مدل در سطوح مختلف تصمیم‌گیری به‌صورت دقیق بررسی گردد. سپس این نتایج در چارچوب مسئله‌ی تشخیص سلول‌های خونی سرطانی تحلیل شده و میزان تعمیم‌پذیری مدل در داده‌های دیده‌نشده مورد ارزیابی قرار می‌گیرد. علاوه بر تحلیل عددی، به نتایج کیفی به‌دست‌آمده از فاز پیش‌آموزش خودنظارتی نیز توجه می‌شود تا نقش یادگیری خودنظارتی مبتنی بر FCMAE در استخراج بازنمایی‌های معنادار از تصاویر پزشکی روشن‌تر گردد. در ادامه، اثر تصمیمات مهندسی اتخاذشده در این پژوهش، از جمله استفاده از معماری ConvNeXt V2 Nano، ماسک‌گذاری پیکسل‌محور، و به‌کارگیری راهبردهای منظم‌سازی، در بهبود عملکرد نهایی مدل مورد بحث قرار می‌گیرد.

در مجموع، فصل چهارم با هدف پاسخ‌گویی به پرسش‌های پژوهش و ارزیابی عملی کارایی روش پیشنهادی تدوین شده است و زمینه‌ی لازم برای جمع‌بندی نهایی، بیان دستاوردها و ارائه‌ی پیشنهادها و پژوهشی در فصل پنجم را فراهم می‌سازد.

۴-۲- دانلود و شناسایی ساختار مجموعه داده سلول‌های خونی برای تشخیص سرطان

در این بخش، فرآیند دریافت خودکار مجموعه داده و شناسایی ساختار آن به‌عنوان نخستین گام اجرایی فاز نتایج ارائه می‌شود. این مرحله نقش پایه‌ای در اطمینان از صحت داده‌ها، شناسایی کلاس‌ها و آماده‌بودن محیط محاسباتی برای اجرای آزمایش‌ها ایفا می‌کند.

این خروجی نشان می‌دهد که مرحله‌ی دانلود و شناسایی داده‌ها به‌صورت کامل و بدون بروز خطا انجام شده است. مجموعه داده‌ی Blood Cell Images for Cancer Detection با موفقیت از مخزن Kaggle دریافت شده و مسیر محلی آن به‌درستی شناسایی گردیده است. در ادامه، پنج کلاس اصلی سلول‌های خونی شامل basophil،

erythroblast, monocyte, myeloblast و seg_neutrophil به‌طور خودکار استخراج شده‌اند که بیانگر تنوع زیستی مناسب و سازگاری داده‌ها با مسئله‌ی طبقه‌بندی پزشکی مورد نظر است. همچنین، فعال بودن CUDA در خروجی نهایی تأیید می‌کند که محیط محاسباتی برای اجرای محاسبات سنگین یادگیری عمیق، به‌ویژه در فازهای پیش‌آموزش خودنظارتی (SSL) و آموزش انتقالی، به‌درستی پیکربندی شده است. در مجموع، این خروجی نشان‌دهنده‌ی صحت پیکربندی داده و سخت‌افزار و پایه‌گذاری صحیح آزمایش‌ها برای مراحل بعدی پژوهش است (شکل ۴-۱).

```
Downloading Blood Cell Dataset...
Dataset ready at: C:\Users\User\.cache\kagglehub\datasets\sumithsingh\blood-cell-images-for-cancer-detection\versions\2
Classes found: ['basophil', 'erythroblast', 'monocyte', 'myeloblast', 'seg_neutrophil']
Device being used: cuda
```

شکل ۴-۱ دالود و شناسایی ساختار مجموعه‌داده سلول‌های خونی برای تشخیص سرطان

۴-۳- تقسیم داده‌ها

پس از دریافت و شناسایی ساختار مجموعه‌داده، گام بعدی تقسیم داده‌ها به زیرمجموعه‌های مستقل برای مراحل مختلف آموزش و ارزیابی مدل است. این مرحله نقش کلیدی در جلوگیری از نشت داده و تضمین ارزیابی منصفانه‌ی عملکرد مدل ایفا می‌کند.

خروجی چاپ‌شده نشان می‌دهد که کل مجموعه‌داده به‌درستی میان چهار بخش اصلی تقسیم شده است. این نسبت‌ها دقیقاً با ساختار طراحی‌شده برای پروژه هم‌خوانی دارند و شامل ۵۰٪ داده‌ها برای یادگیری خودنظارتی، ۲۵٪ برای آموزش در مرحله‌ی تنظیم نهایی، ۱۰٪ برای اعتبارسنجی و ۱۵٪ برای آزمون نهایی هستند. چنین سهم‌بندی‌ای با هدف جلوگیری از نشت داده میان مراحل یادگیری خودنظارتی و آموزش نظارت‌شده انتخاب شده است تا مدل در فاز تنظیم نهایی صرفاً بر پایه‌ی بازنمایی‌های آموخته‌شده و با استفاده از داده‌های جدید و نادیده آموزش ببیند. در عمل، تخصیص ۲۵۰۰ تصویر به مرحله‌ی پیش‌آموزش خودنظارتی (یادگیری بازسازی تصویر)، ۱۷۵۰ تصویر به مراحل آموزش و اعتبارسنجی تنظیم نهایی و ۷۵۰ تصویر مستقل به ارزیابی نهایی، توازن مناسبی میان یادگیری بازنمایی‌های عمومی و آزمون توان انتقالی مدل برقرار می‌کند (شکل ۴-۲). در مجموع، نتایج این مرحله نشان می‌دهد که فرآیند تقسیم داده‌ها به‌صورت موفقیت‌آمیز انجام شده و بنیان آماری و روش‌شناختی کل فرآیند یادگیری و ارزیابی مدل به‌طور صحیح تثبیت شده است.

```
Dataset: SSL=2500, Train=1250, Val=500, Test=750
```

شکل ۴-۲ تقسیم داده‌ها

۴-۴- خروجی فاز اول: یادگیری بدون نظارت

۴-۴-۱- رفتار همگرایی در آموزش خودنظارتی (SSL)

لاگ‌های آموزش نشان می‌دهند که مدل FCMAE طی ۱۵ اپوک به‌صورت پایدار و یکنواخت همگرا شده است. مقدار تابع هزینه‌ی بازسازی (MSE) از حدود ۰/۲۰ در اپوک نخست به حدود ۰/۰۵ در اپوک‌های پایانی کاهش یافته و این کاهش بدون نوسانات شدید یا نشانه‌ای از واگرایی رخ داده است. چنین الگویی بیانگر آن است که مدل به‌تدریج توانسته است ساختارهای آماری و مورفولوژیکی تصاویر سلول‌های خونی را از داده‌های ناقص، با ۶۰٪ پیکسل ماسک‌شده، استخراج کند و فرآیند یادگیری از پایداری مناسبی برخوردار بوده است.

بررسی کیفی تصاویر بازسازی‌شده نشان می‌دهد که مدل، علی‌رغم ورودی‌های به‌شدت ماسک‌شده، قادر است ساختار کلی سلول، شکل هسته، مرزهای سلولی و توزیع رنگ‌های غالب به‌ویژه رنگ بنفش هسته را با صحت قابل قبولی بازسازی کند. هرچند جزئیات بسیار ریز بافتی^۱ تا حدی نرم و هموار شده‌اند، اما اطلاعات معنایی کلیدی^۲ به‌خوبی حفظ شده است. این موضوع نشان می‌دهد که رمزگذار در فاز یادگیری خودنظارتی، به‌جای حفظ پیکسلی تصویر، بازنمایی‌های سطح‌بالا و معنادار از داده‌های زیستی آموخته است.

از منظر بیوانفورماتیکی، توانایی مدل در بازسازی صحیح نواحی هسته و تمایز آن از سیتوپلاسم حتی در شرایط ماسک‌گذاری شدید بیانگر حساس شدن شبکه به ویژگی‌های مرتبط با ریخت‌شناسی سلولی است. این دقیقاً همان نوع بازنمایی است که برای مراحل بعدی تنظیم نهایی در وظیفه‌ی طبقه‌بندی سلول‌های خونی سالم و سرطانی اهمیت حیاتی دارد.

در مجموع، کاهش یکنواخت تابع هزینه و کیفیت بصری مناسب بازسازی تصاویر دیده‌نشده نشان می‌دهد که چارچوب FCMAE مبتنی بر پوشش پیکسل^۳ در این پروژه، علی‌رغم ساده‌سازی نسبت به پیاده‌سازی اصلی مقاله، موفق به یادگیری بازنمایی‌های پایدار، معنادار و قابل انتقال شده است [۹]. این نتایج توجیه علمی محکمی برای استفاده از رمزگذار پیش‌آموزش‌دیده در فاز تنظیم نهایی فراهم می‌کنند و انتظار می‌رود که نقش مؤثری در بهبود تعمیم‌پذیری مدل در مجموعه داده‌ی پزشکی کوچک ایفا نمایند (شکل ۴-۳ و شکل ۴-۴).

^۱ Fine-Grained Textures

^۲ Semantic Structure


^۳ Pixel Masking

```

◆ Phase 1: SSL Pre-training...
SSL Epoch 1: 100% |██████████| 40/40 [00:08<00:00, 4.54it/s, loss=0.2010]
SSL Epoch 2: 100% |██████████| 40/40 [00:08<00:00, 4.53it/s, loss=0.1844]
SSL Epoch 3: 100% |██████████| 40/40 [00:08<00:00, 4.47it/s, loss=0.1518]
SSL Epoch 4: 100% |██████████| 40/40 [00:08<00:00, 4.52it/s, loss=0.1374]
SSL Epoch 5: 100% |██████████| 40/40 [00:09<00:00, 4.35it/s, loss=0.0642]
SSL Epoch 6: 100% |██████████| 40/40 [00:09<00:00, 4.38it/s, loss=0.0857]
SSL Epoch 7: 100% |██████████| 40/40 [00:08<00:00, 4.50it/s, loss=0.0826]
SSL Epoch 8: 100% |██████████| 40/40 [00:08<00:00, 4.57it/s, loss=0.1038]
SSL Epoch 9: 100% |██████████| 40/40 [00:09<00:00, 4.35it/s, loss=0.0564]
SSL Epoch 10: 100% |██████████| 40/40 [00:08<00:00, 4.45it/s, loss=0.0681]
SSL Epoch 11: 100% |██████████| 40/40 [00:08<00:00, 4.50it/s, loss=0.0701]
SSL Epoch 12: 100% |██████████| 40/40 [00:09<00:00, 4.42it/s, loss=0.0524]
SSL Epoch 13: 100% |██████████| 40/40 [00:09<00:00, 4.38it/s, loss=0.0626]
SSL Epoch 14: 100% |██████████| 40/40 [00:08<00:00, 4.50it/s, loss=0.0670]
SSL Epoch 15: 100% |██████████| 40/40 [00:09<00:00, 4.42it/s, loss=0.0540]
Generating SSL Reconstruction Image...

```

شکل ۴-۳ خروجی لاگ مدل FCMAE



شکل ۴-۴ کیفیت بازسازی FCMAE روی داده‌های دیده‌نشده در فاز یادگیری خودنظارتی


۴-۵- نتایج نهایی

۴-۵-۱- تحلیل منحنی‌های آموزش و اعتبارسنجی

نمودارهای هزینه آموزش و ارزیابی و صحت آموزش و ارزیابی نشان می‌دهند که مدل طی ۱۶ دوره‌ی آموزشی به‌صورت مناسب و پایدار همگرا شده است. کاهش مقدار تابع هزینه‌ی آموزش از حدود ۱/۰ در ابتدای فرآیند به کمتر از ۰/۱ در اپوک‌های پایانی بیانگر یادگیری مؤثر مدل از داده‌های آموزشی است. هم‌زمان، مقدار خطای اعتبارسنجی پس از چند نوسان محدود در میانه‌ی آموزش، به یک سطح پایدار رسیده است که این رفتار نشان‌دهنده‌ی نبود بیش‌برازش قابل‌توجه و تعادل مناسب میان یادگیری و تعمیم‌پذیری مدل می‌باشد.

در بخش صحت طبقه‌بندی، افزایش تدریجی صحت آموزش تا نزدیکی ۱۰۰٪ مشاهده می‌شود، در حالی که صحت اعتبارسنجی در بازه‌ی حدود ۹۲ تا ۹۴٪ تثبیت شده است. این فاصله‌ی کنترل‌شده میان صحت آموزش و اعتبارسنجی نشان می‌دهد که مدل اگرچه توان یادگیری بالایی دارد، اما دچار یادگیری صرف الگوهای خاص داده‌های آموزشی نشده و قادر به تعمیم مناسب به داده‌های نادیده است. نسبت بالای صحت اعتبارسنجی نسبت به صحت آموزش همچنین بیانگر اثربخشی راهبردهای منظم‌سازی به‌کاررفته در مدل، از جمله استفاده از Dropout با نرخ ۰/۵ و توقف زودهنگام، در بهبود تعمیم‌پذیری است.

در مجموع، رفتار همگرایی مشاهده‌شده در منحنی‌های خطا و صحت تأیید می‌کند که ترکیب پیش‌آموزش خودنظارتی مبتنی بر FCMAE با تنظیم نهایی نظارت‌شده، منجر به یادگیری پایدار و عملکرد قابل اعتماد مدل در مسئله‌ی طبقه‌بندی تصاویر پزشکی شده است (شکل ۴-۵).



شکل ۴-۵ منحنی‌های آموزش و اعتبارسنجی مدل ConvNeXt V2 مبتنی بر FCMAE

۴-۵-۲- گزارش طبقه‌بندی کمی

نتایج حاصل از گزارش طبقه‌بندی کمی نشان می‌دهد که مقادیر صحت، یادآوری و امتیاز F1 برای هر پنج کلاس سلولی در سطح بسیار بالایی قرار دارند و صحت کلی مدل بر روی مجموعه‌ی آزمون برابر با ۹۴/۸٪ به‌دست آمده است. این مقدار بیانگر عملکرد قوی مدل در تفکیک انواع مختلف سلول‌های خونی در یک سناریوی پزشکی واقعی است.

در میان کلاس‌ها، کلاس میلو بلاست که مهم‌ترین کلاس از منظر تشخیص سرطان محسوب می‌شود، با مقدار بازخوانی برابر با ۱/۰۰ و امتیاز F1 در حدود ۰/۹۸ بالاترین سطح صحت را نشان می‌دهد. این نتیجه بیانگر توان بسیار بالای مدل در شناسایی صحیح سلول‌های سرطانی و کاهش احتمال منفی کاذب است؛ موضوعی که در کاربردهای بالینی اهمیت حیاتی دارد.

سایر کلاس‌ها، از جمله erythroblast و seg_neutrophil نیز عملکردی نزدیک به بی‌نقص از خود نشان داده‌اند که حاکی از توان مدل در تمایز دقیق سلول‌های طبیعی، نابالغ و بالغ است. علاوه بر این، مقدار میانگین کل معیارها^۱ برابر با ۰/۹۴۷ نشان می‌دهد که مدل عملکردی متوازن در تمامی کلاس‌ها داشته و دچار سوگیری نسبت به کلاس‌های پر تعداد یا کم‌نمونه نشده است.

چنین الگویی در پژوهش‌های پزشکی مبتنی بر داده‌های محدود از ارزش بالایی برخوردار است و بیانگر آن است که بازنمایی‌های آموخته‌شده در فاز پیش‌آموزش خودنظارتی (SSL) به‌خوبی به مرحله‌ی یادگیری نظارت‌شده منتقل شده و در تصمیم‌گیری نهایی مدل تثبیت گردیده‌اند (شکل ۴-۶).

Classification Report:				
	precision	recall	f1-score	support
basophil	0.8750	0.9545	0.9130	132
erythroblast	0.9740	0.9434	0.9585	159
monocyte	0.9342	0.8931	0.9132	159
myeloblast	0.9595	1.0000	0.9793	142
seg_neutrophil	0.9934	0.9557	0.9742	158
accuracy			0.9480	750
macro avg	0.9472	0.9493	0.9476	750
weighted avg	0.9495	0.9480	0.9481	750

شکل ۴-۶ گزارش عملکرد مدل

۴-۵-۳- تحلیل ماتریس درهم‌ریختگی

تحلیل ماتریس درهم‌ریختگی نشان می‌دهد که بخش عمده‌ای از نمونه‌ها بر روی قطر اصلی ماتریس، که متناظر با پیش‌بینی‌های صحیح مدل است، متمرکز شده‌اند و مقادیر خارج از قطر اصلی بسیار محدود و ناچیز هستند. این الگو بیانگر صحت بالای مدل در تفکیک کلاس‌های مختلف سلول‌های خونی است.


به‌عنوان نمونه، از میان ۱۵۹ تصویر مربوط به کلاس اریترو بلاست، تعداد ۱۵۰ نمونه به‌درستی شناسایی شده‌اند و تنها تعداد اندکی از تصاویر با کلاس‌های مجاور اشتباه گرفته شده‌اند. همچنین در کلاس مونوسیت، تنها چند مورد خطای جزئی با کلاس بازوفیل مشاهده می‌شود که از منظر بصری و ویژگی‌های بافتی، شباهت طبیعی میان این دو نوع سلول وجود دارد و بروز چنین خطاهایی تا حدی قابل انتظار است.

در مجموع، توزیع خطاها در ماتریس درهم‌ریختگی منظم و محدود بوده و هیچ‌یک از کلاس‌ها دچار خطای سیستماتیک یا سوگیری مشخص نشده‌اند. این موضوع نشان‌دهنده‌ی پایداری^۲ مدل در مواجهه با تنوع

^۱ Macro Average

^۲ Robustness

مورفولوژیکی سلول‌های خونی و توان آن در استخراج ویژگی‌های تمایزگر معنادار از داده‌های پزشکی است (شکل ۷-۴).



شکل ۷-۴ ماتریس درهم‌ریختگی طبقه‌بندی سلول‌های خونی

بررسی منحنی‌های ROC نشان می‌دهد که منحنی‌های مربوط به تمامی کلاس‌ها در نزدیکی گوشه‌ی بالای چپ نمودار قرار گرفته‌اند و مقادیر مساحت زیر منحنی (AUC) در بازه‌ی حدود ۰/۹۹ تا ۱/۰۰ قرار دارند. این الگو بیانگر آن است که مدل در اغلب کلاس‌ها توان جداسازی بسیار بالایی میان نمونه‌های مثبت و منفی دارد و از حساسیت و ویژگی^۱ مطلوبی برخوردار است.

به‌ویژه، دستیابی به مقدار $AUC = 1.00$ برای کلاس‌های اریتروبلست و میلوپلاست از اهمیت بالینی ویژه‌ای برخوردار است، زیرا این دو کلاس نقش کلیدی در تشخیص اختلالات خونی و سرطان خون ایفا می‌کنند. توانایی مدل در تفکیک تقریباً بی‌نقص این کلاس‌ها نشان می‌دهد که تصمیم‌گیری‌های طبقه‌بندی آن می‌تواند به عملکردی قابل اعتماد در کاربردهای پزشکی منجر شود.

در مجموع، نتایج حاصل از تحلیل منحنی‌های ROC تأیید می‌کنند که بازنمایی‌های آموخته‌شده در فاز پیش‌آموزش خودنظارتی، به‌صورت مؤثری به مرحله‌ی طبقه‌بندی منتقل شده‌اند و مدل نهایی از توان بالایی در تمایز دقیق کلاس‌های سلولی برخوردار است (شکل ۸-۴).

¹ Specificity



شکل ۴-۸ منحنی‌های ROC چندکلاسه برای شناسایی سلول‌های خونی

نتایج حاصل از ارزیابی‌های عددی و بصری نشان می‌دهد که مدل ConvNeXt V2 پیش‌آموزش‌دیده در چارچوب FCMAE نه‌تنها فرآیند همگرایی پایدار و روانی را طی کرده است، بلکه به صحت نهایی در حدود ۹۴/۸٪ بر روی مجموعه‌ی آزمون دست یافته است. رفتار مناسب منحنی‌های یادگیری، تمرکز پیش‌بینی‌های صحیح در قطر اصلی ماتریس درهم‌ریختگی و دستیابی به مقادیر AUC نزدیک به ۱ برای تمامی کلاس‌ها، همگی بیانگر عملکرد قوی مدل در تفکیک سلول‌های خونی مختلف هستند.

این نتایج تأیید می‌کنند که مدل به‌صورت مؤثری از بازنمایی‌های آموخته‌شده در فاز پیش‌آموزش خودنظارتی (SSL) در مرحله‌ی طبقه‌بندی پزشکی بهره برده است. پایداری عملکرد و قابلیت تعمیم بالای مدل نشان می‌دهد که رویکرد پیشنهادی، نه‌تنها از منظر روش‌شناختی معتبر است، بلکه می‌تواند به‌عنوان یک راهکار پژوهشی سطح‌بالا برای کاربردهای بالینی و تحلیل‌های زیست‌شناسی سلولی مورد توجه قرار گیرد.

۴-۶- جمع‌بندی

در این فصل، نتایج حاصل از اجرای مدل پیشنهادی مبتنی بر معماری ConvNeXt V2 و پیش‌آموزش خودنظارتی در چارچوب FCMAE به‌صورت جامع ارائه و تحلیل شد. ارزیابی‌ها نشان دادند که مدل در هر دو فاز یادگیری خودنظارتی و تنظیم نهایی نظارت‌شده، رفتار همگرایی پایدار و کنترل‌شده‌ای از خود نشان داده و توانسته است بازنمایی‌های معنادار و قابل انتقالی از تصاویر سلول‌های خونی استخراج کند.

تحلیل منحنی‌های یادگیری بیانگر آن بود که فرآیند آموزش بدون بیش‌برازش قابل توجه انجام شده و استفاده از راهبردهای منظم‌سازی، از جمله Dropout و توقف زودهنگام، نقش مؤثری در بهبود تعمیم‌پذیری مدل ایفا کرده‌اند. در ادامه، نتایج کمی حاصل از گزارش طبقه‌بندی، ماتریس درهم‌ریختگی و منحنی‌های ROC چندکلاسه نشان دادند که مدل نهایی به صحت کلی در حدود ۹۴/۸٪ دست یافته و در تفکیک کلاس‌های بحرانی پزشکی، به‌ویژه سلول‌های سرطانی، عملکردی بسیار قابل اعتماد ارائه داده است.

همچنین، تحلیل‌های کیفی و عددی تأیید کردند که بازنمایی‌های آموخته‌شده در فاز پیش‌آموزش خودنظارتی به‌صورت مؤثری به مرحله‌ی طبقه‌بندی منتقل شده‌اند و مدل توانسته است ویژگی‌های مورفولوژیکی کلیدی سلول‌ها را حتی در شرایط داده‌ی محدود به‌خوبی فرا بگیرد. دستیابی به مقادیر AUC نزدیک به یک برای تمامی کلاس‌ها نشان‌دهنده‌ی توان بالای مدل در تمایز نمونه‌های مثبت و منفی و حساسیت مناسب آن در کاربردهای تشخیصی است.

در مجموع، نتایج این فصل نشان می‌دهند که ترکیب معماری کانولوشنی مدرن ConvNeXt V2 با یادگیری خودنظارتی مبتنی بر FCMAE، رویکردی مؤثر و قابل اتکا برای تحلیل تصاویر پزشکی با داده‌ی محدود فراهم می‌سازد. این دستاوردها مبنای مناسبی برای جمع‌بندی نهایی پژوهش و ارائه‌ی پیشنهادهای توسعه‌ای در فصل بعدی فراهم می‌کنند.

فصل پنجم: جمع‌بندی و نتیجه‌گیری

۵-۱- مقدمه

در فصل‌های پیشین، چارچوب نظری، روش‌شناسی و نتایج حاصل از پیاده‌سازی یک مدل یادگیری عمیق مبتنی بر معماری ConvNeXt V2 و یادگیری خودنظارتی در قالب خودرمزگذار ماسک‌شده‌ی تمام‌کانولوشنی برای تحلیل تصاویر سلول‌های خونی ارائه شد. نتایج تجربی نشان داد که استفاده از پیش‌آموزش خودنظارتی، به‌ویژه در شرایط محدودیت داده‌های برجسب‌دار پزشکی، می‌تواند نقش مؤثری در بهبود تعمیم‌پذیری و صحت مدل‌های یادگیری عمیق ایفا کند.

در این فصل، ابتدا یافته‌های اصلی پژوهش به‌صورت منسجم جمع‌بندی می‌شوند و میزان تحقق اهداف و پاسخ به پرسش‌های تحقیق مورد بررسی قرار می‌گیرد. سپس محدودیت‌های موجود در مسیر انجام پژوهش، از جمله محدودیت‌های داده‌ای، محاسباتی و طراحی معماری، تحلیل می‌شوند. در ادامه، بر اساس نتایج به‌دست‌آمده، پیشنهادهایی برای پژوهش‌های آتی و توسعه‌های کاربردی در حوزه‌ی تشخیص خودکار سرطان خون و تحلیل تصاویر پزشکی ارائه خواهد شد. هدف این فصل، ترسیم تصویری روشن از دستاوردهای پژوهش حاضر و فراهم‌سازی مسیرهای توسعه‌ی علمی و عملی در مطالعات آینده است.

۵-۲- جمع‌بندی کلی پژوهش

در این پژوهش، یک چارچوب یادگیری عمیق مبتنی بر یادگیری خودنظارتی برای تشخیص سلول‌های خونی مرتبط با سرطان طراحی و پیاده‌سازی شد. تمرکز اصلی مطالعه بر به‌کارگیری معماری مدرن ConvNeXt V2 در قالب یک خودرمزگذار ماسک‌شده‌ی تمام‌کانولوشنی (FCMAE) بود تا چالش کمبود داده‌های برجسب‌خورده در حوزه‌ی تصویربرداری پزشکی کاهش یابد. برخلاف بسیاری از رویکردهای کلاسیک که صرفاً بر آموزش نظارت‌شده متکی هستند، در این پروژه مدل ابتدا با استفاده از رمزگذاری خودکار با ماسک پیکسل^۱ و بدون بهره‌گیری از برجسب‌ها پیش‌آموزش داده شد و سپس در مرحله‌ی تنظیم نهایی برای وظیفه‌ی طبقه‌بندی چندکلاسه سلول‌های خونی مورد استفاده قرار گرفت.

طراحی آگاهانه‌ی استراتژی تقسیم داده‌ها (۵۰٪ برای یادگیری خودنظارتی، ۲۵٪ برای آموزش نظارت‌شده، ۱۰٪ برای اعتبارسنجی و ۱۵٪ برای آزمون نهایی) نقش مهمی در جلوگیری از نشت داده ایفا کرد و امکان ارزیابی منصفانه و واقع‌بینانه‌ی تعمیم‌پذیری مدل را فراهم ساخت. این ساختار، به‌ویژه در سناریوهای پزشکی با داده‌ی محدود، از اهمیت بالایی برخوردار است.

¹ Pixel Masked Autoencoding

نتایج تجربی نشان داد که پیش‌آموزش خودنظارتی مبتنی بر FCMAE موجب یادگیری بازنمایی‌های غنی و معنادار از ساختارهای مورفولوژیکی سلول‌های خونی شده است؛ بازنمایی‌هایی که در مرحله‌ی تنظیم نهایی به‌صورت مؤثری به وظیفه‌ی طبقه‌بندی منتقل شدند. دستیابی به صحت نهایی در حدود ۹۴/۸٪، همراه با مقادیر بالای Precision، Recall و F1 Score برای کلاس‌های بحرانی پزشکی، مؤید کارایی این رویکرد در تشخیص سلول‌های سرطانی است.

علاوه بر این، به‌کارگیری راهکارهای منظم‌سازی نظیر Dropout و توقف زودهنگام باعث شد مدل، علی‌رغم ظرفیت بالای معماری ConvNeXt V2، از بیش‌برازش قابل‌توجه جلوگیری کرده و پایداری مناسبی در فرآیند آموزش از خود نشان دهد. تحلیل‌های عددی و بصری، شامل منحنی‌های یادگیری، ماتریس درهم‌ریختگی و منحنی‌های ROC چندکلاسه، همگی بیانگر تعمیم‌پذیری مطلوب و حساسیت بالای مدل در تمایز سلول‌های نرمال و بدخیم هستند.

در مجموع، نتایج این پژوهش نشان می‌دهد که ترکیب معماری‌های کانولوشنی مدرن با چارچوب‌های یادگیری خودنظارتی می‌تواند راهکاری مؤثر و قابل اتکا برای تحلیل تصاویر پزشکی با داده‌ی محدود فراهم آورد و زمینه‌ی مناسبی برای توسعه‌ی سامانه‌های هوشمند تشخیص پزشکی در مطالعات آینده ایجاد کند.

۳-۵- تحلیل نتایج نهایی و دستاوردهای اصلی

نتایج حاصل از فاز یادگیری خودنظارتی نشان داد که مدل FCMAE مبتنی بر معماری ConvNeXt V2 Nano قادر است حتی در شرایط ماسک‌گذاری شدید (حذف ۶۰٪ پیکسل‌های ورودی)، بازنمایی‌های معنادار و پایدار از ساختارهای مورفولوژیکی سلول‌های خونی بیاموزد. کاهش یکنواخت خطای بازسازی از حدود ۲۰٪ در مراحل ابتدایی آموزش به حدود ۰/۰۵ در اپوک‌های پایانی، در کنار کیفیت بصری مناسب بازسازی تصاویر دیده‌نشده، بیانگر آن است که انکودر به ویژگی‌های سطح‌بالا و زیستی مهمی نظیر شکل هسته، مرزهای سلولی و توزیع رنگ حساس شده است. این رفتار نشان می‌دهد که مدل فراتر از بازسازی پیکسلی عمل کرده و به سطحی از یادگیری مفهومی^۱ دست یافته است.

در فاز تنظیم نهایی، انتقال مستقیم وزن‌های انکودر پیش‌آموزش‌دیده به مدل طبقه‌بندی، منجر به بهبود چشمگیر عملکرد در دیتاست پزشکی شد. دستیابی به صحت نهایی ۹۴/۸٪ بر روی مجموعه‌ی آزمون، همراه با مقادیر بالای Precision، Recall و F1 Score برای تمامی کلاس‌ها، نشان‌دهنده‌ی تعمیم‌پذیری بالای مدل در داده‌های

¹ Semantic Learning

دیده نشده است. به‌ویژه، مقدار Recall برابر با $1/0.0$ برای کلاس میلو بلاست از اهمیت بالینی بالایی برخوردار است، زیرا نشان می‌دهد مدل توانایی بسیار مناسبی در شناسایی سلول‌های سرطانی داشته و احتمال بروز خطای منفی کاذب را به حداقل رسانده است.

تحلیل ماتریس درهم‌ریختگی و منحنی‌های ROC چندکلاسه نیز مؤید آن است که خطاهای طبقه‌بندی محدود بوده و عمدتاً میان کلاس‌هایی با شباهت‌های مورفولوژیکی طبیعی رخ داده‌اند. مقادیر بالای AUC برای تمامی کلاس‌ها نشان می‌دهد که مدل در تفکیک نمونه‌های مثبت و منفی از حساسیت و صحت بالایی برخوردار است و رفتار تصمیم‌گیری آن پایدار و قابل اعتماد ارزیابی می‌شود.

در مجموع، دستاوردهای این پژوهش نشان می‌دهد که ترکیب معماری کانولوشنی مدرن ConvNeXt V2 با چارچوب FCMAE و رویکرد یادگیری خودنظارتی می‌تواند یک راهکار مؤثر، مقیاس‌پذیر و قابل اتکا برای مسائل تشخیص پزشکی مبتنی بر تصویر، به‌ویژه در سناریوهای کم‌نمونه و داده‌محور پزشکی، فراهم سازد. این نتایج، ظرفیت بالای رویکرد پیشنهادی را برای توسعه‌ی سامانه‌های هوشمند تشخیص بیماری در مطالعات آینده برجسته می‌کند.

۵-۴- مقایسه مفهومی با رویکردهای متداول

در مقایسه با رویکردهایی که صرفاً بر آموزش نظارت‌شده از ابتدا^۱ متکی هستند، چارچوب پیشنهادی این پژوهش نشان داد که بهره‌گیری از پیش‌آموزش خودنظارتی می‌تواند به‌طور معناداری کیفیت بازنمایی‌های آموخته‌شده توسط مدل را بهبود بخشد. این مزیت به‌ویژه در حوزه‌ی تصویربرداری پزشکی، که برچسب‌گذاری داده‌ها فرآیندی پرهزینه، زمان‌بر و وابسته به تخصص بالینی است، اهمیت دوچندانی پیدا می‌کند.

در روش‌های کلاسیک مبتنی بر یادگیری نظارت‌شده، عملکرد مدل به‌شدت به حجم داده‌های برچسب‌دار وابسته است و در سناریوهای کم‌نمونه، مدل‌ها مستعد بیش‌برازش و یادگیری الگوهای سطحی هستند. در مقابل، چارچوب FCMAE با استفاده از یادگیری خودنظارتی و بدون اتکا به برچسب‌ها، مدل را وادار می‌کند تا ساختارهای درونی و پایدار تصویر را پیش از مواجهه با وظیفه‌ی طبقه‌بندی بیاموزد. این ویژگی باعث می‌شود بازنمایی‌های استخراج‌شده در مرحله‌ی تنظیم نهایی غنی‌تر، تعمیم‌پذیرتر و کمتر وابسته به نویزهای داده‌ای باشند.

همچنین، در مقایسه با روش‌های متداول مبتنی بر افزایش داده^۲ که عمدتاً بر تغییرات ظاهری تصویر تمرکز دارند، FCMAE با حذف هدفمند بخش قابل توجهی از ورودی و الزام مدل به بازسازی اطلاعات از دست‌رفته، شبکه را

¹ Training from Scratch

² Data Augmentation

به یادگیری روابط فضایی، الگوهای مورفولوژیکی و وابستگی‌های ساختاری عمیق سوق می‌دهد. این تفاوت مفهومی موجب می‌شود مدل به‌جای اتکا به نشانه‌های سطحی، به ویژگی‌های زیستی معنادار حساس شود؛ امری که در تشخیص پزشکی از اهمیت حیاتی برخوردار است.

نتایج تجربی این پژوهش با یافته‌های گزارش‌شده در مقاله‌ی ConvNeXt V2 هم‌راستا بوده و نشان می‌دهد که مزایای ترکیب معماری‌های کانولوشنی مدرن با چارچوب‌های یادگیری خودنظارتی، حتی در مقیاس کوچک^۱ و بر روی دیتاست‌های پزشکی با حجم محدود نیز حفظ می‌شوند. این موضوع بیانگر آن است که رویکرد پیشنهادی، نه‌تنها از منظر تئوریک معتبر است، بلکه از نظر عملی نیز برای کاربردهای واقعی پزشکی قابلیت استفاده و توسعه دارد [۹].

۵-۵- محدودیت‌های پژوهش

با وجود نتایج امیدوارکننده، این پژوهش با چند محدودیت همراه است. نخست، مجموعه‌داده‌ی مورد استفاده از نظر تنوع جمعیتی، شرایط تصویربرداری و گستره‌ی بالینی محدود بوده و بنابراین تعمیم مستقیم نتایج به تمامی سناریوهای درمانی نیازمند احتیاط است. دوم، در این پروژه چارچوب افسی‌ام‌ای بر پایه‌ی ماسک‌گذاری پیکسلی پیاده‌سازی شده است، در حالی که نسخه‌ی اصلی مقاله از ماسک‌گذاری در سطح ویژگی و کانولوشن تنک بهره می‌برد؛ هرچند عملکرد مدل نشان داد این ساده‌سازی مانع یادگیری مؤثر نشده، اما مقایسه‌ی تجربی مستقیم این دو رویکرد می‌تواند تحلیل دقیق‌تری ارائه دهد [۹]. در نهایت، ارزیابی مدل صرفاً بر مبنای شاخص‌های آماری انجام شده و تحلیل کیفی توسط متخصص بالینی در این مرحله لحاظ نشده است که می‌تواند در مطالعات آینده تکمیل گردد.

۵-۶- پیشنهادات مطالعات آتی

در ادامه‌ی این پژوهش، مسیرهای متعددی برای توسعه و بهبود کار قابل پیشنهاد است. نخست، می‌توان کانولوشن تنک واقعی را مطابق با پیاده‌سازی اصلی افسی‌ام‌ای به‌کار گرفت و اثر آن را به‌صورت تجربی با ماسک‌گذاری پیکسلی مقایسه کرد تا تحلیل دقیق‌تری از تفاوت‌های معماری ارائه شود. دوم، استفاده از مجموعه‌داده‌های بزرگ‌تر و چندمرکزی می‌تواند امکان ارزیابی جامع‌تر تعمیم‌پذیری مدل را در شرایط واقعی بالینی فراهم سازد. سوم، بررسی انتقال یادگیری مدل پیش‌آموزش‌دیده به سایر وظایف هماتولوژی، نظیر تشخیص مراحل بیماری یا طبقه‌بندی نرمال/غیرنرمال، می‌تواند ارزش کاربردی چارچوب پیشنهادی را افزایش دهد.

¹ Nano

علاوه بر این، ترکیب معماری ConvNeXt V2 با رویکردهای هوش مصنوعی قابل توضیح، مانند گراد-کم یا مصورسازی نواحی توجه، می تواند شفافیت تصمیم گیری مدل را ارتقا داده و اعتمادپذیری آن را برای کاربردهای بالینی افزایش دهد. در نهایت، گسترش این چارچوب به داده های چندوجهی شامل تصویر به همراه داده های بالینی یا ژنتیکی، می تواند گام مهمی در مسیر توسعه سامانه های هوشمند جامع برای تشخیص و پایش سرطان خون محسوب شود.

مراجع

- [1] Y. LeCun, Y. Bengio, and G. Hinton, “Deep learning,” *Nature*, vol. 521, no. 7553, pp. 436–444, 2015.
- [2] A. Krizhevsky, I. Sutskever, and G. Hinton, “ImageNet Classification with Deep Convolutional Neural Networks,” *Neural Inf. Process. Syst.*, vol. 25, Jan. 2012, doi: 10.1145/3065386.
- [3] G. Litjens *et al.*, “A survey on deep learning in medical image analysis,” *Med. Image Anal.*, vol. 42, pp. 60–88, 2017, doi: <https://doi.org/10.1016/j.media.2017.07.005>.
- [4] L. Jing and Y. Tian, “Self-supervised visual feature learning with deep neural networks: A survey,” *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 43, no. 11, pp. 4037–4058, 2020.
- [5] K. He, X. Chen, S. Xie, Y. Li, P. Dollár, and R. Girshick, “Masked autoencoders are scalable vision learners,” in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2022, pp. 16000–16009.
- [6] Z. Liu, H. Mao, C.-Y. Wu, C. Feichtenhofer, T. Darrell, and S. Xie, “A convnet for the 2020s,” in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2022, pp. 11976–11986.
- [7] S.-C. Huang, A. Pareek, M. Jensen, M. P. Lungren, S. Yeung, and A. S. Chaudhari, “Self-supervised learning for medical image classification: a systematic review and implementation guidelines,” *npj Digit. Med.*, vol. 6, no. 1, p. 74, 2023, doi: 10.1038/s41746-023-00811-0.
- [8] N. Jia *et al.*, “A fine-grained image classification algorithm based on self-supervised learning and multi-feature fusion of blood cells,” *Sci. Rep.*, vol. 14, no. 1, p. 22964, 2024, doi: 10.1038/s41598-024-74753-2.
- [9] S. Woo *et al.*, “Convnext v2: Co-designing and scaling convnets with masked autoencoders,” in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2023, pp. 16133–16142.
- [10] H. Bao, L. Dong, S. Piao, and F. Wei, “Beit: Bert pre-training of image transformers,” *arXiv Prepr. arXiv2106.08254*, 2021.
- [11] T. Chen, S. Kornblith, M. Norouzi, and G. Hinton, “A simple framework for contrastive learning of visual representations,” in *International conference on machine learning*, PmLR, 2020, pp. 1597–1607.
- [12] Kaggle, “Blood Cell images for Cancer detection.” Accessed: Feb. 10, 2026. [Online]. Available: <https://www.kaggle.com/datasets/sumithsingh/blood-cell-images-for-cancer-detection>
- [13] H. Touvron, M. Cord, A. Sablayrolles, G. Synnaeve, and H. Jégou, “Going deeper with image transformers,” in *Proceedings of the IEEE/CVF international conference on computer vision*, 2021, pp. 32–42.